

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG - HCM
KHOA TOÁN - TIN HỌC



Môn: Thống kê Nhiều chiều

BÁO CÁO ĐỒ ÁN MÔN HỌC

**PHÂN TÍCH THỐNG KÊ TRÊN CÁC HỆ DỮ
LIỆU ĐA CHIỀU: TỪ CÁC YẾU TỐ HÀNH VI
ĐẾN DỰ BÁO SUY THOÁI ĐỘNG CƠ C-MAPSS**

Giáo viên hướng dẫn: Nguyễn Thị Mộng Ngọc

Nhóm sinh viên thực hiện:

Họ tên	MSSV
1. Nguyễn Minh Quang	23110203
2. Nguyễn Hoàng Phúc	23110201
3. Hà Tuấn Kiệt	23110176

Thành phố Hồ Chí Minh, 2026

Tóm tắt nội dung

Nghiên cứu này trình bày một hệ phương pháp luận toàn diện trong việc ứng dụng Thống kê Nhiều chiều (Multivariate Statistics) nhằm khai phá tri thức, trích xuất đặc trưng và lập mô hình trên ba cơ sở dữ liệu mang cấu trúc và đặc thù thống kê chuyên biệt: y tế học (Sleep Health), xã hội học giáo dục (Student Habits) và tín hiệu cảm biến chuỗi thời gian (NASA C-MAPSS). Thông qua việc tích hợp các kỹ thuật phân tích ma trận hiệp phương sai, giảm chiều trực giao và học máy thống kê, báo cáo đã giải quyết đa chiều các bài toán định lượng. Cụ thể, trên miền dữ liệu y tế, sự kết hợp giữa PCA và kiểm định MANOVA đã lượng hóa thành công cấu trúc phân mảnh triệu chứng, xác thực hệ quả tổn thương đồng thời lên cả hệ tim mạch và thần kinh do hội chứng ngưng thở khi ngủ. Trong bối cảnh phân tích hành vi giáo dục, việc đối chiếu chéo giữa MANOVA, Hồi quy Tuyến tính Đa biến (Multivariate LR) và phân cụm K-Means đã cung cấp bằng chứng thống kê vững chắc về sự chi phối tuyệt đối của thời lượng tự học lên vector thành quả học thuật, đồng thời phơi bày ranh giới vi phạm tuyến tính do hiệu ứng trần (ceiling effect) của thang đo. Đáng chú ý, đối với hệ thống động lực cơ học (C-MAPSS), nghiên cứu đề xuất một chuỗi xử lý tín hiệu khép kín: ứng dụng Bộ lọc Kalman (Kalman Filter) để khử nhiễu động học (zero-lag smoothing), sử dụng PCA/EFA nhằm cô lập biến cấu trúc suy thoái (Degradation Component), và thiết lập các chuẩn kiểm soát thống kê (Khoảng cách Mahalanobis, Hotelling T^2 , GMM) để tự động hóa quá trình nhận diện điểm chuyển pha lỗi. Kết quả thực nghiệm tổng thể không chỉ khẳng định năng lực ưu việt của thống kê đa chiều trong việc bóc tách biến nhiễu, kiểm soát lạm phát sai lầm Loại I và diễn giải các cấu trúc ngầm định (latent constructs), mà còn thiết lập một khuôn khổ thực tiễn vững chắc trải dài từ phân tích hành vi đến bảo trì tiên đoán (predictive maintenance).

Mục lục

1	Mở đầu (Introduction)	7
1.1	Lý do chọn đề tài (Motivation)	7
1.2	Mục tiêu và Câu hỏi Nghiên cứu (Research Objectives & Questions)	7
1.3	Các Tập dữ liệu sử dụng (Datasets)	8
2	Cơ sở lý thuyết (Theoretical Background)	10
2.1	Các kỹ thuật Giảm chiều và Trích xuất Đặc trưng	10
2.2	Các mô hình Phân tích Đa biến	10
2.3	Các thuật toán Khám phá và Xử lý tín hiệu	11
2.4	Các tiêu chuẩn đánh giá mô hình	11
3	Phương pháp luận (Methodology)	12
3.1	Phương pháp phân tích Dữ liệu Sleep Health and Lifestyle	12
3.2	Phương pháp phân tích Dữ liệu Student Habits Performance	13
3.3	Phương pháp phân tích Dữ liệu Động cơ C-MAPSS (NASA)	14
4	Kết quả và Phân tích (Results & Analysis)	14
4.1	Phần 1: Phân tích Dữ liệu Sleep Health and Lifestyle	14
4.1.1	Khám phá và Tiền xử lý dữ liệu (EDA)	15
4.1.2	Đánh giá tính phù hợp của Dữ liệu và Phân tích Thành phần Chính (PCA)	18
4.1.3	Kiểm chứng chéo bằng Phân tích Nhân tố Khám phá (EFA)	21
4.1.4	Phân tích Phương sai Nhiều chiều (MANOVA) và Hậu định (Tukey HSD)	24
4.1.5	Tổng kết Phần 1 (Conclusion)	26
4.2	Phần 2: Phân tích Dữ liệu Student Habits Performance	26
4.2.1	Tiền xử lý Dữ liệu	26
4.2.2	Lựa chọn Phương pháp (Method Selection)	30
4.2.3	Kiểm tra các Giả định và Tính phù hợp của Dữ liệu	30
4.2.4	Thực hiện Phân tích các Mô hình (Model Estimation)	33
4.2.5	Tổng hợp kết quả Phần 2 (Cross-Method Synthesis)	42
4.2.6	Tổng kết Phần 2 (Conclusion)	42
4.3	Phần 3: Dự báo Suy thoái Động cơ Máy bay C-MAPSS	43
4.3.1	Khám phá Đặc trưng Cơ học (EDA)	43
4.3.2	Tiền xử lý Dữ liệu (Data Preprocessing)	44
4.3.3	Kiểm định Giả định Thống kê và Lựa chọn Số lượng Thành phần Chính	48
4.3.4	Trích xuất Chỉ số Sức khỏe bằng PCA và EFA	50

4.3.5	Phân tích Quỹ đạo Sức khỏe và Cảnh báo sớm	54
4.3.6	Bộ lọc Kalman, Phân cụm GMM và Phân tích Biệt thức	56
4.3.7	Đánh giá Hiệu năng Hồi quy (RMSE) và Phần dư	58
4.3.8	Tổng kết Phần 3 (Conclusion)	59
5	Thảo luận và Hướng phát triển (Discussion & Future Directions)	60
5.1	Tổng hợp và Ý nghĩa Thực tiễn (Cross-Domain Practical Implications) . .	60
5.2	Giới hạn chung của các Phương pháp (Methodological Limitations)	60
5.3	Định hướng phát triển theo Thống kê Nhiều chiều (Advanced Statistical Directions)	61
6	Kết luận (Conclusion)	62
	Tài liệu tham khảo	63
	Bảng Phân Công Công Việc	65
	Phụ lục: Mã nguồn và Dữ liệu	66

Danh sách hình vẽ

1	So sánh phân phối dữ liệu trước và sau khi chuẩn hóa Z-score	16
2	Ma trận tương quan Pearson giữa các chỉ số sinh học và lối sống	17
3	Biểu đồ Scree Plot xác định số lượng Thành phần chính (PC)	19
4	Tương quan biến số (PC1 và PC2)	20
5	Tương quan biến số (PC3 và PC4)	20
6	Biplot phân cụm Bệnh nhân theo Rối loạn giấc ngủ (PC1 và PC2)	21
7	Biểu đồ Parallel Analysis so sánh Eigenvalue	22
8	Heatmap Ma trận Tải nhân tố EFA	23
9	Đồ thị thanh Communalities (h^2)	23
10	Ma trận Boxplot so sánh 4 Thành phần chính (PC) theo nhóm Rối loạn giấc ngủ	25
11	Biểu đồ phân phối điểm thi (Exam Score)	28
12	Biểu đồ phân tán giữa thói quen sinh hoạt và điểm thi.	29
13	Phân phối Boxplot của các thói quen sinh hoạt và điểm thi.	29
14	Ma trận tương quan Spearman giữa các biến định lượng và thứ bậc.	31
15	Biểu đồ Q-Q Plot kiểm tra phân phối chuẩn của các biến mục tiêu.	32
16	Biểu đồ Chi-square Q-Q Plot kiểm tra ngoại lai đa chiều.	39
17	Đồ thị chẩn đoán phần dư (Residual Diagnostics) cho ba phương trình hồi quy.	40
18	Tín hiệu thô của 4 cảm biến tiêu biểu (Động cơ #1). Xu hướng suy thoái bị nhiễu che lấp.	43
19	Ma trận Tương quan: Mức độ tương quan rất cao chứng tỏ sự tồn tại của Đa cộng tuyến.	44
20	Phân phối dữ liệu gốc của 14 Cảm biến: Sự chênh lệch khổng lồ về thang đo đòi hỏi phải chuẩn hóa.	45
21	Biểu đồ Boxplot phân tán của 14 cảm biến sau khi chuẩn hóa Min-Max.	46
22	So sánh hiệu quả lọc nhiễu trên Cảm biến S4: Kalman Filter khử nhiễu bám sát thực tế, trong khi Moving Average bị trễ pha.	47
23	Biểu đồ Normal Q-Q Plot từ kiểm định Mardia: Đuôi trên lệch chuẩn nghiêm trọng, phản ánh quá trình suy thoái cực đoan.	48
24	Biểu đồ Screeplot: PC_1 chiếm tỷ trọng lớn với 79.4% phương sai giải thích.	49
25	Parallel Analysis: Đối chiếu Eigenvalues thực tế và mô phỏng, đề xuất giữ lại 2 PC.	50
26	Trọng số các biến (Variables): Các vectơ cảm biến phân bổ chủ yếu dọc theo trục PC_1 , chứng tỏ sự đóng góp lớn vào phương sai chung.	50
27	Phân bố quan sát: Sự dịch chuyển tọa độ từ trái sang phải tương ứng với sự suy giảm RUL (màu xanh $\rightarrow$ cam/đỏ).	51

28	Biplot: Kết hợp quan sát và biến, thể hiện "lực kéo" của từng cảm biến lên xu hướng thoái hóa chung.	51
29	Trọng số (Loadings) của 3 Thành phần chính đầu tiên: PC_1 (màu xanh lá) chiếm trọn sự chi phối từ đa số các cảm biến cốt lõi.	52
30	Biểu đồ Communalities: Tất cả các cảm biến đều có mức độ giải thích vượt xa ngưỡng 0.5.	53
31	Quỹ đạo Chỉ số Sức khỏe (PC_1 Kalman) của 5 động cơ ngẫu nhiên.	54
32	Đường cong Cảnh báo sớm dựa trên Khoảng cách Mahalanobis đa chiều.	55
33	Biểu đồ Kiểm soát Hotelling T^2 : Cảnh báo sớm với ngưỡng UCL dựa trên phân phối F.	55
34	Đường cong BIC: Đỉnh cao nhất tại $G = 5$, nhưng $G = 3$ được chọn vì tính thực tiễn cơ học.	56
35	Phân cụm GMM ($G = 3$) tự động nhận diện 3 pha suy thoái trên PC_1 (Động cơ 1).	56
36	Không gian PC_1 - PC_2 với Ellipse tin cậy 95%: 3 vùng trạng thái tách biệt rõ ràng.	57
37	Phân tích Phần dư (Residuals): Phần dư phân tán ngẫu nhiên, mô hình không bị thiên lệch và đáp ứng giả định phương sai đồng nhất (Homoscedasticity).	59

Danh sách bảng

1	Thống kê mô tả các biến định lượng của dữ liệu Sleep Health	15
2	Kết quả kiểm định KMO và Bartlett's Test	18
3	Độ lệch chuẩn và tỷ lệ phương sai giải thích của 4 PC đầu tiên	19
4	Ma trận hệ số tải nhân tố (Rotated Factor Loadings) và Hệ số chung (Communalities - h^2)	23
5	Kết quả kiểm định MANOVA (Pillai's Trace)	24
6	Kết quả phân tích hậu định Tukey HSD (Adjusted p-value)	24
7	Phân loại các biến số trong bộ dữ liệu Student Habits	27
8	Tóm tắt thống kê cơ bản các biến định lượng	27
9	Trích xuất một phần dữ liệu sau khi mã hóa (10 quan sát đầu tiên)	28
10	Tương quan Spearman giữa các biến phản hồi	32
11	Chỉ số MSA (Measure of Sampling Adequacy) cho từng biến	33
12	Kết quả kiểm định Omnibus MANOVA (Wilks' Λ)	34
13	Kết quả kiểm định Omnibus Multivariate LR (Wilks' Λ)	35
14	So sánh bản chất kiểm định giữa MANOVA và MLR	35
15	Kết quả kiểm định Type III MANOVA (Wilks' Λ) cho mô hình MLR	36
16	Sức giải thích của ba phương trình hồi quy	37
17	Profile tác động đa chiều của các biến cốt lõi (β^*)	37

18	Tóm tắt chỉ số VIF của mô hình	38
19	Kết quả kiểm định Breusch-Pagan cho ba phương trình	38
20	Kết quả kiểm định Ramsey RESET	39
21	So sánh các chỉ số đánh giá phân cụm theo số cụm k	41
22	Thống kê mô tả (Profile) của các cụm K-Means (k=3)	41
23	Chênh lệch điểm thi trung bình giữa các cụm (Tukey HSD)	42
24	Ma trận Trọng số Nhân tố (Factor Loadings) từ EFA	52
25	Chỉ số Communality của các cảm biến	53
26	Kết quả Phân tích Biệt thức Tuyến tính (LDA) trên 3 cụm GMM	57
27	Bảng tổng hợp so sánh hiệu năng Hồi quy và Kiểm định Thống kê	58

1 Mở đầu (Introduction)

1.1 Lý do chọn đề tài (Motivation)

Trong bối cảnh kỷ nguyên số và Cách mạng Công nghiệp 4.0, dữ liệu đang bùng nổ không chỉ về quy mô (Volume) mà còn về số lượng chiều biểu diễn (Dimensionality). Khác với các mô hình thống kê đơn biến truyền thống, thực tiễn khoa học ngày nay đòi hỏi các phương pháp có khả năng phân tích đồng thời sự tương tác đan xen giữa hàng chục, thậm chí hàng trăm biến số. Việc ứng dụng **Thống kê Nhiều chiều (Multivariate Statistics)** [6, 7] chính là "chìa khóa" quyết định giúp các nhà phân tích bóc tách nhiễu, giảm thiểu sự dôi dư thông tin, và phát hiện ra các cấu trúc ẩn (Latent Structures) mang tính hệ thống. Nhằm kiểm chứng sức mạnh của các phương pháp toán học này, đề án được thực hiện với mục tiêu ứng dụng đa dạng các mô hình thống kê hiện đại lên ba bài toán thực tế có độ phức tạp cao, trải dài từ lĩnh vực y tế dự phòng, khoa học hành vi xã hội, cho đến giám sát bảo trì động cơ hàng không.

1.2 Mục tiêu và Câu hỏi Nghiên cứu (Research Objectives & Questions)

Đề án hướng tới việc áp dụng linh hoạt các kỹ thuật thống kê đa chiều để giải mã 3 bài toán nghiên cứu cốt lõi:

1. Đối với dữ liệu Sức khỏe và Giấc ngủ (Sleep Health and Lifestyle): Dựa trên đặc thù của hệ sinh lý cơ thể người - nơi các chỉ số có tính liên kết chặt chẽ và tương quan cao, nghiên cứu đặt ra hai câu hỏi chính:

- **Khám phá và Giảm chiều dữ liệu:** Liệu mạng lưới 9 chỉ số sinh lý và hành vi phức tạp (huyết áp, nhịp tim, số bước chân, mức độ căng thẳng...) có thể được nén thành các trục không gian sức khỏe độc lập và cốt lõi hay không?
- **Đánh giá tác động đa lượng:** Tình trạng bệnh lý (Ngưng thở khi ngủ, Mất ngủ) có tạo ra sự chấn động đồng thời trên toàn bộ các trục sức khỏe đó hay không, và khía cạnh nào phải gánh chịu mức độ tổn thương nặng nề nhất?

2. Đối với dữ liệu Thói quen và Thành tích Sinh viên (Student Habits Performance):

Tiếp cận theo lăng kính xã hội học, nơi các biến phân loại và định lượng đan xen, đề án giải quyết ba vấn đề:

- **Phân tích sự khác biệt nhóm:** Việc tham gia thị trường lao động sớm (làm thêm) hoặc các hoạt động ngoại khóa có làm thay đổi có ý nghĩa thống kê lên toàn bộ vector kết quả (điểm thi, sức khỏe tinh thần, chuyên cần) của sinh viên không?
- **Đánh giá tác động đa chiều:** Các thói quen vi mô hàng ngày (giờ học, giờ dùng

mạng xã hội, giờ ngủ) định hình kết quả học tập và tinh thần của sinh viên như thế nào dưới góc độ Hồi quy Đa biến (Multivariate Linear Regression)?

- **Nhận diện hành vi:** Có thể sử dụng thuật toán không giám sát để phân mảnh sinh viên thành các "hệ sinh thái hành vi" (behavioral clusters) đặc trưng không?

3. Đối với dữ liệu Động cơ Máy bay NASA C-MAPSS (Predictive Maintenance):

Đại diện cho bài toán chuỗi thời gian cơ học với tính phi tuyến và nhiễu động học cao, câu hỏi cốt lõi được đặt ra là:

- **Trích xuất tín hiệu và Dự báo vòng đời:** Bằng cách nào có thể khử nhiễu tín hiệu (Noise Filtering) và khắc phục hiện tượng đa cộng tuyến (Multicollinearity) từ 14 cảm biến nhiệt động học, để trích xuất ra một quỹ đạo suy thoái cốt lõi duy nhất nhằm phục vụ cho cơ chế cảnh báo sớm và dự báo vòng đời hữu ích còn lại (RUL) của động cơ?

1.3 Các Tập dữ liệu sử dụng (Datasets)

Để trả lời các câu hỏi nghiên cứu đa diện, đồ án khai thác ba bộ dữ liệu độc lập, mang tính đại diện cho ba mô hình cấu trúc dữ liệu kinh điển trong phân tích thống kê đa chiều:

1. Dữ liệu Y tế - Lối sống: Sleep Health and Lifestyle Dataset [15]

- **Quy mô và Đặc tính:** Bao gồm 374 quan sát (dưới dạng nghiên cứu cắt ngang - cross-sectional) và 13 biến số. Dữ liệu phác họa bức tranh y khoa tại một thời điểm của người trưởng thành.
- **Cấu trúc Biến:**
 - *Nhóm biến sinh lý - y khoa (Sinh trắc học):* Nhịp tim tĩnh (`Heart.Rate`), Huyết áp tâm thu/tâm trương (`Blood.Pressure`). Đây là các biến định lượng liên tục (Continuous) phản ánh áp lực cơ học thực tế lên hệ tuần hoàn.
 - *Nhóm biến lối sống - hành vi:* Số bước chân hàng ngày (`Daily.Steps`), Mức độ vận động thể chất (`Physical.Activity.Level`), Thời lượng ngủ (`Sleep.Duration`).
 - *Nhóm biến phân loại (Categorical/Ordinal):* Mức độ căng thẳng (`Stress.Level`, thang điểm 1-10), BMI Category, và biến mục tiêu phân nhóm bệnh lý (`Sleep.Disorder`: None, Insomnia, Sleep Apnea).
- **Thách thức Thống kê:** Sự tồn tại của đa cộng tuyến (Multicollinearity) mạnh giữa các chỉ số sinh lý (ví dụ: Huyết áp và Nhịp tim) đòi hỏi áp dụng kỹ thuật nén chiều (PCA/EFA) làm tiền đề bắt buộc trước khi thực hiện các phép kiểm định giả thuyết đa lượng (MANOVA).

2. Dữ liệu Xã hội học - Hành vi: Student Habits and Performance [16]

- **Quy mô và Đặc tính:** Bao gồm 1000 quan sát và 16 biến số. Đây là bộ dữ liệu hỗn hợp (mixed-type data) tiêu biểu để phân tích hành vi trong khoa học giáo dục.
- **Cấu trúc Biến:**
 - *Vector biến phản hồi (Dependent Variables):* Tổ hợp hệ quả đầu ra gồm Điểm thi (`exam_score`), Sức khỏe tinh thần (`mental_health_rating`), và Tỷ lệ chuyên cần (`attendance_percentage`).
 - *Vector biến giải thích (Predictors):* Gồm biến liên tục đo lường cường độ phân bổ thời gian (giờ tự học, dùng mạng xã hội, xem Netflix, thời gian ngủ) kết hợp với các biến định danh phân loại (tham gia làm thêm, ngoại khóa).
- **Thách thức Thống kê:** Đòi hỏi kiến trúc Hồi quy Tuyến tính Đa biến (Multivariate Linear Regression) để tính toán đồng thời ma trận hệ số $\mathbf{B}$ cho hệ đa phản hồi, đồng thời phải nhận diện và xử lý rào cản về "hiệu ứng trần" (ceiling effect) do đặc tính bị chặn trên (upper-bounded) của thang đo điểm số.

3. Dữ liệu Chuỗi thời gian Cơ học: NASA C-MAPSS (FD001) [14]

- **Quy mô và Đặc tính:** Đây là bộ dữ liệu đo lường viễn trắc (Telemetry Data) với khối lượng đồ sộ, mô phỏng quá trình hoạt động của hạm đội 100 động cơ phản lực thương mại cho đến khi hỏng hoàn toàn (Run-to-Failure). Chỉ riêng tập huấn luyện (Train) đã chứa trên 20,631 chuỗi thời gian (time-series records).
- **Cấu trúc Biến:**
 - *Biến đầu vào (Features):* 21 cảm biến (Sensors) ghi nhận các đại lượng vật lý đặc trưng (lưu lượng dòng khí, áp suất tĩnh, nhiệt độ buồng đốt) tại các phân hệ cốt lõi của động cơ (Fan, LPC, HPC, LPT, HPT) thay đổi theo từng chu kỳ hoạt động.
 - *Biến mục tiêu (Target):* Vòng đời hữu ích còn lại (Remaining Useful Life - RUL), một đại lượng liên tục tiệm cận về 0.
- **Thách thức Thống kê:** Tín hiệu suy thoái vật lý bị vùi lấp sâu dưới lớp nhiễu ngẫu nhiên (white noise) sinh ra bởi rung lắc cơ học và quá trình đốt cháy, kết hợp với quỹ đạo thoái hóa mang bản chất phi tuyến (non-linear degradation). Bài toán buộc phải tích hợp chéo nhiều phương pháp: Lý thuyết Lọc tín hiệu động (Kalman Filter), Giảm chiều (PCA) và Học máy Không giám sát (GMM) để phát hiện trạng thái lỗi.

2 Cơ sở lý thuyết (Theoretical Background)

2.1 Các kỹ thuật Giảm chiều và Trích xuất Đặc trưng

Phân tích Thành phần Chính (PCA): Là phương pháp biến đổi trực giao nhằm chuyển đổi một tập hợp các biến có khả năng tương quan thành một tập hợp các biến không tương quan tuyến tính gọi là các thành phần chính (Principal Components). Phương pháp này hoạt động dựa trên việc phân tích trị riêng (Eigenvalue decomposition) của ma trận hiệp phương sai hoặc ma trận tương quan Σ , thỏa mãn phương trình:

$$\Sigma \mathbf{v} = \lambda \mathbf{v} \quad (1)$$

Từ đó tối đa hóa phương sai giải thích với số lượng chiều dữ liệu nhỏ nhất [6, 7, 8, 9].

Phân tích Biệt thức Tuyến tính (LDA): Khác với PCA, LDA là kỹ thuật giảm chiều có giám sát (supervised dimensionality reduction). Phương pháp này tìm kiếm các trục tọa độ (Linear Discriminants) $\mathbf{w}$ thông qua việc tối đa hóa hàm mục tiêu Fisher (Fisher's criterion):

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}} \quad (2)$$

nhằm tối đa hóa phương sai giữa các nhóm ($\mathbf{S}_B$) và tối thiểu hóa phương sai trong nội bộ nhóm ($\mathbf{S}_W$), qua đó cung cấp không gian chiếu tối ưu để phân tách dữ liệu theo nhãn phân lớp [7, 9].

Phân tích Nhân tố Khám phá (EFA): Khác với PCA tập trung vào việc giảm chiều dữ liệu thuần túy, EFA nhằm mục đích phát hiện các cấu trúc ẩn (Latent Constructs) chưa biết chi phối các biến quan sát. Bằng cách sử dụng ma trận hệ số tải (Factor Loadings) và các phép xoay trực giao (như Varimax), EFA giúp tối ưu hóa khả năng diễn giải ý nghĩa của từng nhân tố [6, 8].

2.2 Các mô hình Phân tích Đa biến

Phân tích Phương sai Nhiều chiều (MANOVA): Là phiên bản mở rộng của ANOVA khi có từ hai biến phụ thuộc trở lên. Thay vì kiểm định ANOVA nhiều lần (gây rủi ro lạm phát sai lầm Loại I), MANOVA so sánh sự khác biệt của các nhóm độc lập trên một vector trung bình đa chiều. Việc đánh giá ý nghĩa thống kê thường dựa trên tiêu chuẩn Wilks' Λ , được định nghĩa bởi:

$$\Lambda = \frac{|\mathbf{W}|}{|\mathbf{B} + \mathbf{W}|} \quad (3)$$

với $\mathbf{B}$ và $\mathbf{W}$ lần lượt là ma trận tổng bình phương giữa các nhóm (Between) và trong nội bộ nhóm (Within) [6, 8, 9].

Hồi quy Tuyến tính Đa biến (Multivariate Linear Regression): Là kỹ thuật mở rộng từ hồi quy tuyến tính đơn biến, cho phép dự báo đồng thời nhiều biến phụ thuộc liên tục dựa trên cùng một hệ thống các biến độc lập. Phương pháp này biểu diễn dưới dạng ma trận $\mathbf{Y} = \mathbf{XB} + \mathbf{E}$, giúp ước lượng ma trận hệ số $\mathbf{B}$ cho toàn bộ hệ thống và nắm bắt được sự tương quan chéo giữa các biến phụ thuộc [6, 9].

2.3 Các thuật toán Khám phá và Xử lý tín hiệu

Phân cụm K-Means & Mô hình Hỗn hợp Gauss (GMM): K-Means là thuật toán học không giám sát phân mảnh dữ liệu thành K cụm dựa trên việc tối thiểu hóa tổng khoảng cách Euclid bình phương:

$$\arg \min \sum_{i=1}^K \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2 \quad (4)$$

Trong khi đó, GMM linh hoạt hơn bằng cách giả định dữ liệu được sinh ra từ một hỗn hợp của nhiều phân phối chuẩn đa chiều với hàm mật độ $p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$, cho phép mô hình hóa các cụm có hình dạng elip và mức độ chồng lấn phức tạp [5, 12].

Bộ lọc Trung bình Động (Moving Average - MA): Là kỹ thuật làm mịn chuỗi thời gian bằng cách tính giá trị trung bình của dữ liệu trong một cửa sổ trượt (sliding window) cố định. Mặc dù dễ cài đặt và hiệu quả trong việc khử nhiễu ngẫu nhiên, MA thường gây ra độ trễ pha (phase lag) đối với các tín hiệu động học [10].

Bộ lọc Kalman (Kalman Filter): Là một thuật toán đệ quy tối ưu, sử dụng cơ chế cập nhật không gian trạng thái động gồm hai bước "Dự đoán - Cập nhật" (Predict-Update). Thuật toán này liên tục tính toán độ bất định để tự động cân bằng giữa mô hình toán học dự báo và tín hiệu đo lường thực tế, qua đó khử nhiễu tín hiệu hiệu quả mà không gây trễ pha (zero-lag) như MA [11].

Đo lường khoảng cách đa chiều: Khoảng cách Mahalanobis là một thước đo khoảng cách điểm dữ liệu đa biến so với tâm phân phối, có tính đến sự tương quan hiệp phương sai $\boldsymbol{\Sigma}$:

$$D^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \quad (5)$$

Từ đó, Biểu đồ kiểm soát Hotelling T^2 sử dụng phân phối F để thiết lập các ngưỡng giới hạn trên (UCL), giúp phát hiện tự động các quan sát bất thường mang tính hệ thống [7].

2.4 Các tiêu chuẩn đánh giá mô hình

Tiêu chuẩn thông tin Bayes (BIC - Bayesian Information Criterion): Là tiêu chuẩn được thiết kế để lựa chọn mô hình bằng cách thiết lập sự cân bằng giữa độ phù

hợp của mô hình (Log-likelihood) và mức độ phức tạp của nó (số lượng tham số k), nhằm tránh hiện tượng quá khớp (overfitting). BIC được định nghĩa là:

$$BIC = k \ln(n) - 2 \ln(\hat{L}) \quad (6)$$

với n là cỡ mẫu và $\hat{L}$ là giá trị cực đại của hàm hợp lý (Likelihood function). Trong bài báo cáo, BIC đóng vai trò cốt lõi trong việc xác định số lượng cụm (GMM/K-Means) tối ưu [13].

Sai số Bình phương Trung bình Căn (RMSE - Root Mean Square Error): Là thước đo phổ biến để đánh giá độ chính xác của các mô hình hồi quy và dự báo chuỗi thời gian, được tính bằng:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (7)$$

RMSE nhạy cảm với các sai số dự báo lớn (do tác động bình phương), điều này đặc biệt hữu ích trong các bài toán dự báo rủi ro kỹ thuật như thời gian RUL của động cơ [10].

3 Phương pháp luận (Methodology)

Để đạt được các mục tiêu nghiên cứu đã đề ra, đề án xây dựng các luồng quy trình phân tích (analytical pipelines) chuyên biệt, phù hợp với đặc tính thống kê của từng bộ dữ liệu.

3.1 Phương pháp phân tích Dữ liệu Sleep Health and Lifestyle

Quy trình phân tích tập trung vào việc giảm chiều dữ liệu và đánh giá tác động của các yếu tố nguy cơ dẫn đến rối loạn giấc ngủ (Sleep Disorder):

- **Tiền xử lý & Khám phá:** Kiểm tra dữ liệu khuyết thiếu. Tách biến Huyết áp (Blood.Pressure) thành Huyết áp tâm thu (Systolic) và Huyết áp tâm trương (Diastolic) để tính toán định lượng. Loại bỏ các biến định danh không mang ý nghĩa thống kê và mã hóa Factor các biến phân loại. Thực hiện chuẩn hóa Z-score (Scaling) để đưa các biến về cùng một hệ quy chiếu, đảm bảo tính công bằng khi tính toán ma trận hiệp phương sai. Các giá trị ngoại lai y khoa (như nhịp tim cao) được giữ nguyên để bảo toàn đặc trưng bệnh lý.
- **Khám phá và Giảm chiều dữ liệu (PCA):** Áp dụng Phân tích Thành phần Chính (PCA) nhằm nén thông tin, trích xuất các biến rời rạc thành một số ít các Thành phần chính độc lập [6, 7], phục vụ cho mô hình MANOVA ở giai đoạn sau.
- **Phân tích Phương sai Nhiều chiều (MANOVA):** Sử dụng MANOVA thay vì

các phép ANOVA đơn lẻ để tránh lạm phát sai lầm Loại I (Type I Error) khi đánh giá đồng thời trên một tổ hợp tuyến tính các nhân tố sức khỏe [8]. Sự khác biệt cụ thể giữa từng nhóm rối loạn giấc ngủ sẽ được đánh giá chi tiết bằng phân tích hậu định Tukey HSD.

3.2 Phương pháp phân tích Dữ liệu Student Habits Performance

Bộ dữ liệu gồm 1000 quan sát hoàn chỉnh không khuyết thiếu, kết hợp giữa biến liên tục và biến phân loại. Để giải quyết toàn diện mối quan hệ giữa hệ sinh thái thói quen sinh hoạt và thành tích học thuật, nghiên cứu áp dụng 3 quy trình phân tích độc lập nhưng bổ trợ cho nhau:

- **Thiết kế Biến số và Tiền xử lý (Research Design & Preprocessing):** Dựa trên khung lý thuyết về sự gắn kết sinh viên (Fredricks et al., 2004) và các nghiên cứu về thói quen học tập [4], nghiên cứu thiết lập một vector phản hồi đa chiều bậc ba $Y = (\text{exam_score}, \text{mental_health_rating}, \text{attendance_percentage})$. Do hạn chế của dữ liệu cắt ngang (cross-sectional), nghiên cứu không cố gắng thiết lập mô hình nhân quả mà xem đây là các hệ quả bậc ba đồng thời. Các giá trị ngoại lai y khoa (như điểm số rất thấp) được giữ lại do mang ý nghĩa thực tiễn. Ma trận tương quan Spearman xác nhận không tồn tại hiện tượng đa cộng tuyến nghiêm trọng.
- **Kiểm tra Giả định (Assumptions Check):** Việc phân tích sử dụng biến phân loại 4 nhóm tổ hợp hành vi (đi làm thêm $\times$ ngoại khóa), với nhóm nhỏ nhất (Yes-Yes) có $n=64$. Giả định đồng nhất ma trận hiệp phương sai được thỏa mãn thông qua kiểm định Box's M ($p = 0.7305 > 0.05$). Việc khảo sát ngoại lai đa chiều bằng khoảng cách Mahalanobis không phát hiện điểm cực đoan nào. Tính phân phối chuẩn đa biến được bảo đảm bởi Định lý Giới hạn Trung tâm nhờ cỡ mẫu lớn ($n = 1000$).
- **Mô hình MANOVA:** So sánh trung bình của vector kết quả Y giữa các nhóm phân loại (đi làm thêm và hoạt động ngoại khóa) bằng tiêu chuẩn Wilks' Λ [9], qua đó kiểm soát rủi ro lạm phát sai lầm Loại I so với kiểm định ANOVA riêng lẻ.
- **Hồi quy Tuyến tính Đa biến (Multivariate LR):** Ước lượng đồng thời tác động biên của toàn bộ hệ thống biến sinh hoạt liên tục (thời gian học, thời gian sử dụng mạng xã hội, giấc ngủ...) lên vector Y [8]. Phương pháp này cho phép so sánh cấu trúc hệ số β giữa 3 phương trình con. Độ vững của mô hình được kiểm định qua chẩn đoán VIF, Breusch-Pagan và Ramsey RESET.
- **Phân cụm K-Means (K-Means Clustering):** Đóng vai trò phân tích khám phá (Unsupervised Learning) nhằm phân nhóm hành vi sinh viên dựa trên thói quen

sinh hoạt [5]. Số cụm tối ưu $k = 3$ được quyết định dựa trên phương pháp Elbow và chỉ số Silhouette, tiếp đó áp dụng ANOVA để kiểm chứng sự khác biệt về điểm thi giữa các cụm.

3.3 Phương pháp phân tích Dữ liệu Động cơ C-MAPSS (NASA)

Dữ liệu chuỗi thời gian cơ học mang đặc tính nhiễu động học (dynamic noise) và đa cộng tuyến rất cao. Quy trình xử lý yêu cầu sự kết hợp giữa Toán học và Kiến thức Vật lý:

- **Xây dựng Biến mục tiêu (RUL):** Biến Thời gian sống hữu ích còn lại (Remaining Useful Life) được tính toán ngược từ chu kỳ hỏng hóc [1]. Áp dụng kỹ thuật *Piece-wise Linear Degradation* (Cắt trần RUL ở 125 chu kỳ) để phản ánh đúng thực tế vật lý: động cơ không suy thoái trong giai đoạn đầu vận hành.
- **Nén chiều & Giải thích vật lý (PCA & EFA):** Rút gọn 14 cảm biến có độ tương quan cao thành Thành phần chính đầu tiên (PC_1) làm Chỉ số sức khỏe [2]. Sử dụng EFA (phép xoay Varimax) để minh bạch hóa ý nghĩa vật lý (tách biệt quá trình mài mòn và biến thiên thứ cấp).
- **Lọc nhiễu & Phân cụm (Kalman Filter & GMM):** Sử dụng Bộ lọc Kalman 1 chiều để khử nhiễu tần số cao trên PC_1 [11]. Áp dụng Mô hình Hỗn hợp Gauss (GMM) tối ưu hóa qua chỉ số BIC để phân tách tự động 3 pha suy thoái [12].
- **Đo lường Khoảng cách & Dự báo:** Xây dựng biểu đồ kiểm soát Hotelling T^2 phục vụ cảnh báo sớm [7]. Cuối cùng, dùng Hồi quy đa thức (Polynomial Regression) trên PC_1 để dự báo RUL.

4 Kết quả và Phân tích (Results & Analysis)

Quy ước trình bày giả thuyết thống kê: Mỗi kiểm định giả thuyết được trình bày theo format rút gọn " H_0 : [phát biểu]" và " H_1 : [phủ định]".

4.1 Phần 1: Phân tích Dữ liệu Sleep Health and Lifestyle

Trong bối cảnh y tế dự phòng hiện đại, sức khỏe tổng thể của con người không chỉ phụ thuộc vào các chỉ số y khoa đơn lẻ mà còn chịu sự chi phối mạnh mẽ từ hệ sinh thái lối sống và chất lượng giấc ngủ hàng ngày. Nhằm lượng hóa mối quan hệ đa chiều này, nghiên cứu tiến hành phân tích bộ dữ liệu `SleepHealthLifestyle.csv` bao gồm 374 quan sát với 13 biến số.

4.1.1 Khám phá và Tiền xử lý dữ liệu (EDA)

Kết quả kiểm tra dữ liệu ban đầu cho thấy không có bất kỳ giá trị khuyết thiếu (missing values) nào trên toàn bộ 374 quan sát. Bảng 1 trình bày tóm tắt thống kê mô tả (Descriptive Statistics) của các biến định lượng sinh học và lối sống, cho thấy sự đa dạng và độ phân tán lớn về thang đo giữa các biến.

Bảng 1: Thống kê mô tả các biến định lượng của dữ liệu Sleep Health


Biến số	Giá trị nhỏ nhất	Trung vị	Trung bình	Giá trị lớn nhất
Age (Tuổi)	27.0	43.0	42.18	59.0
Sleep.Duration (Giờ ngủ)	5.8	7.2	7.13	8.5
Quality.of.Sleep (Chất lượng ngủ)	4.0	7.0	7.31	9.0
Physical.Activity.Level (Mức độ vận động)	30.0	60.0	59.17	90.0
Stress.Level (Mức độ căng thẳng)	3.0	5.0	5.38	8.0
Heart.Rate (Nhịp tim)	65.0	70.0	70.17	86.0
Daily.Steps (Số bước chân)	3000	7000	6817	10000

Kế tiếp, tiến hành xử lý các biến đặc thù. Biến **Blood Pressure** ban đầu được ghi nhận dưới dạng chuỗi ký tự (String/Character), ví dụ: “120/80”. Định dạng này khiến các phần mềm máy tính hiểu đây là dữ liệu định danh hoặc văn bản thuần túy, hoàn toàn không thể thực hiện các phép toán đại số tuyến tính (như tính trung bình, phương sai, hiệp phương sai). Về mặt y học, huyết áp bao gồm hai chỉ số có ý nghĩa lâm sàng hoàn toàn khác biệt: Huyết áp tâm thu (**Systolic** - áp lực khi tim co bóp) và Huyết áp tâm trương (**Diastolic** - áp lực khi tim thả lỏng). Việc tách chuỗi ký tự này thành hai cột số thực liên tục (Continuous Numeric) là bắt buộc để các thuật toán PCA và MANOVA có thể tính toán ma trận hiệp phương sai của hệ tuần hoàn.

Đồng thời, cột **Person.ID** bị loại bỏ hoàn toàn khỏi tập dữ liệu. Đây chỉ là mã số định danh, không mang lại thông tin gì về mặt sinh học, việc giữ lại có thể gây nhiễu hoặc sai lệch trong quá trình tính toán.

Các biến **Gender**, **Occupation**, **BMI.Category** và **Sleep.Disorder** được chuẩn hóa thành kiểu dữ liệu **Factor**. Kỹ thuật Phân tích thành phần chính (PCA) được xây dựng trên nền tảng khoảng cách Euclid và ma trận hệ số tương quan tuyến tính Pearson, vốn chỉ áp dụng cho biến định lượng liên tục [6]. Do đó, các biến phân loại (Categorical variables) không thỏa mãn tính chất này sẽ bị loại khỏi bước trích xuất nhân tố PCA. Tuy nhiên, chúng không bị xóa bỏ mà được giữ lại nguyên vẹn làm biến độc lập phân nhóm cho mô hình kiểm định MANOVA/ANOVA ở các giai đoạn sau.

Sau khi chuẩn hóa dữ liệu bằng phương pháp Z-score (đưa về trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$), các biến được đưa về cùng một hệ quy chiếu, khắc phục hiện tượng lệch phương sai do sự chênh lệch lớn về đơn vị đo lường.



Hình 1: So sánh phân phối dữ liệu trước và sau khi chuẩn hóa Z-score


Quan sát Hình 1, ở biểu đồ dữ liệu gốc (trái), biến số `Daily.Steps` với giá trị hàng ngàn đã lấn át hoàn toàn và làm "phẳng hóa" đồ thị hộp của tất cả các biến số học khác. Tuy nhiên, sau khi thực hiện chuẩn hóa (biểu đồ phải), dữ liệu đã được đồng nhất về mặt tỷ lệ. Điều này không chỉ giúp các thuật toán phân tích đa chiều đánh giá công bằng mức độ đóng góp của từng biến, mà còn làm lộ rõ các điểm dị biệt (outliers) ở biến `Heart.Rate` (các chấm màu đỏ), đại diện cho những cá nhân có nhịp tim cao bất thường trong bộ dữ liệu.

Phân tích Ma trận tương quan Pearson (Hình 2) chỉ ra sự tồn tại của các mối quan hệ tương quan đồng biến và nghịch biến nội tại vô cùng mạnh mẽ, tạo thành các cụm đặc trưng lâm sàng rõ nét:

- **Cụm Tim mạch và Lão hóa:** `Systolic` và `Diastolic` có mức độ tương quan đồng biến gần như tuyệt đối ($r = 0.97$). Đáng chú ý, `Age` (Tuổi) có tương quan thuận khá mạnh với huyết áp tâm thu ($r = 0.61$) và tâm trương ($r = 0.59$), phản ánh đúng thực tế y khoa về sự suy giảm độ đàn hồi thành mạch và nguy cơ cao huyết áp khi con người già đi.

- **Cụm Lối sống Năng động:** `Daily.Steps` và `Physical.Activity.Level` có tương quan thuận mạnh ($r = 0.77$), cho thấy số bước chân hàng ngày phản ánh rất trung thực mức độ vận động tổng thể của mỗi cá nhân.
- **Cụm Căng thẳng và Giấc ngủ:** `Stress.Level` có sức phá hủy vô cùng lớn đến bức tranh sức khỏe chung. Nó tương quan nghịch cực kỳ sâu sắc với `Quality.of.Sleep` ($r = -0.90$) và `Sleep.Duration` ($r = -0.81$). Ngược lại, thời lượng và chất lượng giấc ngủ hỗ trợ tương hỗ mạnh mẽ cho nhau ($r = 0.88$).
- **Sự biến thiên của Nhịp tim:** `Heart.Rate` có mối quan hệ đồng biến với `Stress.Level` ($r = 0.67$) và nghịch biến với `Quality.of.Sleep` ($r = -0.66$). Điều này chứng minh rằng căng thẳng thần kinh làm tăng nhịp tim cơ sở, từ đó phá vỡ cấu trúc và chất lượng của giấc ngủ.

Correlation Matrix



Hình 2: Ma trận tương quan Pearson giữa các chỉ số sinh học và lối sống

Chính sự tồn tại của cấu trúc tương quan phức tạp và hiện tượng đa cộng tuyến này đã khẳng định sự bắt buộc phải sử dụng Phân tích Thành phần chính (PCA) để khử nhiễu và giảm chiều dữ liệu.

4.1.2 Đánh giá tính phù hợp của Dữ liệu và Phân tích Thành phần Chính (PCA)

Trước khi chạy mô hình PCA, tính phù hợp của dữ liệu được đánh giá thông qua hệ số KMO (Kaiser-Meyer-Olkin) và kiểm định tính cầu Bartlett.

Chỉ số KMO tổng thể đạt $0.61 \geq 0.5$, chứng tỏ các biến chia sẻ đủ lượng thông tin chung để có thể trích xuất thành phần.

Đối với kiểm định tính cầu Bartlett, ta thiết lập giả thuyết:


- Giả thuyết H_0 : Ma trận tương quan của tổng thể là ma trận đơn vị (không có sự tương quan tuyến tính giữa các biến).
- Giả thuyết H_1 : Ma trận tương quan của tổng thể khác ma trận đơn vị.

Kết quả kiểm định Bartlett cho thấy p -value xấp xỉ 0 (với $\chi^2 = 3992.346, df = 36$). Do đó, ta hoàn toàn bác bỏ giả thuyết H_0 , khẳng định rằng giữa các biến có tồn tại mối tương quan tuyến tính có ý nghĩa thống kê và tập dữ liệu là phù hợp để thực hiện PCA (Bảng 2).

Bảng 2: Kết quả kiểm định KMO và Bartlett's Test

Kiểm định	Giá trị thống kê	p-value
Kaiser-Meyer-Olkin (KMO)	0.61	-
Bartlett's Test of Sphericity	$\chi^2 = 3992.346$ (df = 36)	≈ 0

Dựa trên tiêu chuẩn điểm gãy (Elbow Method) trên đồ thị Scree Plot (Hình 3), điểm gãy xuất hiện rõ rệt tại vị trí từ PC4 sang PC5. Việc giữ lại 4 PC đảm bảo giảm chiều hiệu quả mà không làm thất thoát cấu trúc thông tin quan trọng. Tổng phương sai giải thích tích lũy đạt tới 93.85% (Bảng 3).



Hình 3: Biểu đồ Scree Plot xác định số lượng Thành phần chính (PC)


Bảng 3: Độ lệch chuẩn và tỷ lệ phương sai giải thích của 4 PC đầu tiên

Thành phần	Độ lệch chuẩn (SD)	% Phương sai	% Tích lũy
PC1	1.8720	38.94%	38.94%
PC2	1.6697	30.98%	69.91%
PC3	1.2452	17.23%	87.14%
PC4	0.7769	6.71%	93.85%


Dựa trên ma trận hệ số tải và đồ thị Biplot (Hình ??), các Thành phần chính được định danh và mang ý nghĩa y sinh học như sau:

- **PC1 (Trục Giấc ngủ & Căng thẳng):** Phân tách trạng thái sức khỏe/phục hồi (thời lượng và chất lượng ngủ cao) đối lập với trạng thái căng thẳng sinh lý (stress cao, nhịp tim cao).
- **PC2 (Trục Tim mạch & Lão hóa):** Phân tách rõ rệt dựa trên hệ số tải cực lớn của Huyết áp Tâm thu và Tâm trương, đồng thời chịu ảnh hưởng của Tuổi tác.

- **PC3 (Trục Vận động & Huyết áp):** Phản ánh sự đối lập giữa mức độ hoạt động thể chất thực tế và các đặc điểm huyết áp liên quan đến tuổi tác.
- **PC4 (Trục Biến thiên nhịp tim):** Bộc lộ các biến thiên bất thường và đặc thù của nhịp tim độc lập với các hệ thống khác.




Hình 4: Tương quan biến số (PC1 và PC2)



Hình 5: Tương quan biến số (PC3 và PC4)


Tiếp theo, việc trực quan hóa sự phân bố của các bệnh nhân trên không gian PCA là cực kỳ quan trọng để chuẩn bị cho kiểm định MANOVA. Đồ thị Biplot kép (Hình 6) dưới đây thể hiện cách mà hội chứng Rối loạn giấc ngủ phân tách các quan sát trên mặt phẳng của 2 thành phần chính cốt lõi nhất (PC1 và PC2).



Hình 6: Biplot phân cụm Bệnh nhân theo Rối loạn giấc ngủ (PC1 và PC2)

4.1.3 Kiểm chứng chéo bằng Phân tích Nhân tố Khám phá (EFA)


Để kiểm chứng chéo độ vững chắc của cấu trúc dữ liệu và làm sắc nét hơn ý nghĩa sinh lý học của các nhân tố, phương pháp Phân tích Nhân tố Khám phá (EFA) được triển khai. Dựa trên kết quả đề xuất từ biểu đồ Parallel Analysis (Hình 7), việc giữ lại từ 3 đến 4 nhân tố là hoàn toàn khả thi. Nhằm thuận tiện đối chiếu với 4 thành phần chính của PCA, nhóm quyết định cố định số nhân tố trích xuất là 4, kết hợp thuật toán Maximum Likelihood (ml) và phép xoay trục giao Varimax.




Hình 7: Biểu đồ Parallel Analysis so sánh Eigenvalue

Kết quả EFA (Bảng 24) cho thấy các biến quan sát được nhóm thành 4 nhân tố cực kỳ rõ nét và sát với kết quả PCA:

- **Nhân tố ML3 (Giải thích 36.3% phương sai):** Nhóm các biến Quality of Sleep (0.97), Sleep Duration (0.91), và Stress Level (-0.92).
- **Nhân tố ML2 (Giải thích 26.9% phương sai):** Nhóm Systolic (0.98), Diastolic (0.95), và Age (0.70).
- **Nhân tố ML1 (Giải thích 19.8% phương sai):** Nhóm Daily Steps (0.97) và Physical Activity Level (0.89).
- **Nhân tố ML4 (Giải thích 6.0% phương sai):** Nhóm Heart Rate (0.55) và có sự phân tán với Physical Activity.



Hình 8: Heatmap Ma trận Tải nhân tố EFA



Hình 9: Đồ thị thanh Communality (h^2)

Bảng 4: Ma trận hệ số tải nhân tố (Rotated Factor Loadings) và Hệ số chung (Communality - h^2)

Biến số	ML3	ML2	ML1	ML4	h^2
Age	0.44	0.70	-	-	0.71
Sleep.Duration	0.91	-	-	-	0.83
Quality.of.Sleep	0.97	-	-	-	0.97
Physical.Activity.Level	-	-	0.89	0.35	0.97
Stress.Level	-0.92	-	-	-	0.88
Heart.Rate	-0.62	-	-	0.55	0.70
Daily.Steps	-	-	0.97	-	1.00
Systolic	-	0.98	-	-	0.99
Diastolic	-	0.95	-	-	0.98

Ba nhân tố đầu tiên giải thích 83.1% tổng phương sai của dữ liệu. Bên cạnh đó, giá trị Communality (h^2) của đa số các biến đều lớn hơn 0.70, đặc biệt các biến **Daily.Steps** và **Systolic** đạt xấp xỉ tuyệt đối (> 0.99). Điều này chứng tỏ phần lớn phương sai của các biến đã được giải thích trọn vẹn bởi các nhân tố chung.

Sự khác biệt giữa PCA và EFA xuất phát từ bản chất thuật toán: PCA tối đa hóa lượng thông tin giữ lại (phục vụ mục tiêu giảm chiều dữ liệu), trong khi EFA hướng tới việc khám phá cấu trúc ẩn (giúp việc diễn giải khoa học dễ dàng hơn). Vì mục tiêu cốt lõi của nghiên cứu là xây dựng các vector đầu vào toàn diện nhất cho kiểm định MANOVA, nhóm nghiên cứu thống nhất sử dụng 4 thành phần trích xuất từ mô hình PCA làm kết quả chính thức.

4.1.4 Phân tích Phương sai Nhiều chiều (MANOVA) và Hậu định (Tukey HSD)

Mô hình MANOVA được thiết lập để kiểm định giả thuyết: Liệu tình trạng rối loạn giấc ngủ (None, Insomnia, Sleep Apnea) có tạo ra sự chênh lệch có ý nghĩa thống kê trên cấu trúc sức khỏe đa chiều (Vector PC1-PC4) hay không.

Khảo sát điều kiện đồng nhất của các ma trận hiệp phương sai bằng Box's M Test cho thấy giá trị $\chi^2 = 369.87$ ($df = 20$) với p -value xấp xỉ 0 ($< 2.2 \times 10^{-16}$). Điều này chứng tỏ dữ liệu vi phạm giả định đồng nhất. Do đó, tiêu chuẩn **Pillai's Trace** được sử dụng do tính bền vững mạnh mẽ trước sự vi phạm này (Bảng 5).

Bảng 5: Kết quả kiểm định MANOVA (Pillai's Trace)


Nguồn biến thiên	Df	Pillai	Approx F	Num Df	Den Df	Pr(>F)
Sleep.Disorder	2	0.878	72.236	8	738	$< 2.2 \times 10^{-16}$ ***
Residuals	371					

Với mức ý nghĩa $p \approx 0$, ta bác bỏ H_0 . Điều này cung cấp bằng chứng thống kê mạnh mẽ khẳng định hội chứng rối loạn giấc ngủ có tác động đáng kể làm phá vỡ cấu trúc tổng thể trên cả 4 khía cạnh sức khỏe.

Để định vị chính xác hội chứng nào tàn phá khía cạnh nào, kiểm định hậu định Tukey HSD được triển khai. Bảng 6 tóm tắt các giá trị p -value đã hiệu chỉnh (Adjusted p-value):

Bảng 6: Kết quả phân tích hậu định Tukey HSD (Adjusted p-value)

Cặp so sánh	PC1 (Tâm lý)	PC2 (Tim mạch)	PC3 (Vận động)	PC4 (Nhịp tim)
None vs Insomnia	≈ 0	10^{-7}	≈ 0	0.0003
None vs Sleep Apnea	0.000089	≈ 0	0.0005	0.069 (ns)
Insomnia vs Sleep Apnea	0.367 (ns)	≈ 0	0.000005	0.000002



Hình 10: Ma trận Boxplot so sánh 4 Thành phần chính (PC) theo nhóm Rối loạn giấc ngủ

Diễn giải chuyên sâu:

- Tổn thương Tâm lý & Thần kinh (PC1):** Mất ngủ và Ngưng thở khi ngủ đều tàn phá sức khỏe tinh thần và chất lượng giấc ngủ một cách nghiêm trọng so với người khỏe mạnh ($p \approx 0$). Mức độ tàn phá của hai bệnh này trên trục này là tương đương nhau ($p = 0.367$).
- Cú sốc Tim mạch (PC2):** Trục PC2 phân biệt rõ rệt hội chứng Ngưng thở khi ngủ (Sleep Apnea). Bệnh nhân thuộc nhóm này phải gánh chịu áp lực hệ tim mạch (huyết áp cao) nặng nề và tăng vọt một cách bất thường, bỏ xa cả người bị mất ngủ thông thường và người bình thường ($p \approx 0$). Kết quả này hoàn toàn tương đồng với các nghiên cứu y khoa lâm sàng về mối liên hệ giữa ngưng thở khi ngủ và rủi ro tim mạch [3].
- Đặc thù Nhịp tim (PC4):** Bệnh nhân Mất ngủ (Insomnia) bộc lộ sự tổn thương và bất thường ở nhịp tim khác biệt hoàn toàn so với quần thể người khỏe mạnh và người bị ngưng thở ($p < 0.001$).

4.1.5 Tổng kết Phần 1 (Conclusion)

Nghiên cứu đã giải quyết trọn vẹn hai mục tiêu đề ra đối với hệ thống dữ liệu y tế đa chiều. Thứ nhất, việc ứng dụng Phân tích Thành phần Chính (PCA) và Phân tích Nhân tố Khám phá (EFA) đã chứng minh khả năng nén mạng lưới 9 chỉ số sinh lý phức tạp thành 4 không gian sức khỏe cốt lõi độc lập, loại bỏ hoàn toàn hiện tượng đa cộng tuyến nội tại. Thứ hai, thông qua mô hình Phân tích Phương sai Đa lượng (MANOVA) và hậu định Tukey HSD, nghiên cứu khẳng định tình trạng bệnh lý Rối loạn giấc ngủ tạo ra cú sốc chấn động đồng thời trên toàn bộ các trục không gian sức khỏe. Cụ thể, bệnh nhân Mất ngủ (Insomnia) chịu tổn thương nặng nề nhất ở khía cạnh tâm lý, thần kinh và biến thiên nhịp tim độc lập; trong khi đó, hội chứng Ngưng thở khi ngủ (Sleep Apnea) tạo ra áp lực suy kiệt kép, tàn phá nghiêm trọng cả hệ tuần hoàn (huyết áp) lẫn chất lượng phục hồi giấc ngủ. Kết quả này cung cấp bằng chứng định lượng sắc bén để cá nhân hóa phác đồ điều trị y khoa.

4.2 Phần 2: Phân tích Dữ liệu Student Habits Performance

4.2.1 Tiền xử lý Dữ liệu

Trong bối cảnh giáo dục đại học hiện đại, thành tích học thuật của sinh viên không chỉ phụ thuộc vào năng lực nhận thức mà còn chịu sự chi phối mạnh mẽ từ hệ sinh thái lối sống và thói quen sinh hoạt hàng ngày. Để lượng hóa mối quan hệ này, nghiên cứu tiến hành phân tích bộ dữ liệu `StudentHabitsPerformance.csv`. Bộ dữ liệu bao gồm **1000 quan sát** với **16 biến số**, bao quát các khía cạnh: từ thời lượng học tập, chất lượng giấc ngủ, sức khỏe tâm thần, cho đến mức độ tiêu thụ mạng xã hội và các hoạt động ngoại khóa.

Khởi tạo và kiểm tra dữ liệu khuyết thiếu

Bộ dữ liệu bao gồm 1000 quan sát (sinh viên) và 16 biến, được phân loại trong Bảng 7. Kết quả kiểm tra xác nhận toàn bộ 16 biến đều hoàn chỉnh, không có giá trị khuyết thiếu (Missing Values - NA).


Bảng 7: Phân loại các biến số trong bộ dữ liệu Student Habits

STT	Tên biến	Mô tả	Loại biến
1	student_id	Mã định danh sinh viên	Định danh
2	age	Tuổi	Định lượng (Liên tục)
3	gender	Giới tính	Phân loại (Nominal)
4	study_hours_per_day	Số giờ tự học mỗi ngày	Định lượng (Liên tục)
5	social_media_hours	Số giờ dùng MXH mỗi ngày	Định lượng (Liên tục)
6	netflix_hours	Số giờ xem Netflix mỗi ngày	Định lượng (Liên tục)
7	part_time_job	Có đi làm thêm hay không	Phân loại (Nhị phân)
8	attendance_percentage	Tỷ lệ chuyên cần (%)	Định lượng (Liên tục)
9	sleep_hours	Số giờ ngủ mỗi ngày	Định lượng (Liên tục)
10	diet_quality	Chất lượng dinh dưỡng	Thứ bậc (Ordinal)
11	exercise_frequency	Tần suất tập thể dục (lần/tuần)	Định lượng (Rời rạc)
12	parental_education_level	Trình độ học vấn phụ huynh	Thứ bậc (Ordinal)
13	internet_quality	Chất lượng Internet	Thứ bậc (Ordinal)
14	mental_health_rating	Đánh giá sức khỏe tinh thần (1–10)	Định lượng (Rời rạc)
15	extracurricular_participation	Tham gia hoạt động ngoại khóa	Phân loại (Nhị phân)
16	exam_score	Điểm thi cuối kỳ	Định lượng - Biến mục tiêu

Bảng 8: Tóm tắt thống kê cơ bản các biến định lượng

Biến	Min	Median	Mean	Max
study_hours_per_day	0.0	3.5	3.55	8.3
social_media_hours	0.0	2.5	2.51	7.2
netflix_hours	0.0	1.8	1.82	5.4
sleep_hours	3.2	6.5	6.47	10.0
attendance_percentage	56.0	84.4	84.13	100.0
exercise_frequency	0.0	3.0	3.04	6.0
mental_health_rating	1.0	5.0	5.44	10.0
exam_score	18.4	70.5	69.60	100.0

Bảng tóm tắt thống kê cơ bản các biến định lượng (Bảng 8) và biểu đồ Histogram (Hình 11) cho thấy phân phối điểm thi (exam_score) có độ lệch nhẹ, với đuôi kéo dài về phía điểm thấp. Có dấu hiệu tích tụ ở vùng điểm cao (48 quan sát đạt 100 điểm), phù hợp với hiệu ứng trần của thang đo giới hạn điểm.



Hình 11: Biểu đồ phân phối điểm thi (Exam Score)


Mã hóa biến và Khảo sát ngoại lai

Biến định danh `student_id` được loại bỏ. Các biến phân loại thứ bậc (`diet_quality`, `parental_education_level`, `internet_quality`) được mã hóa thành Factor với các mức độ tăng dần. Để phục vụ cho mô hình hồi quy, tất cả các biến phân loại đều sử dụng dummy coding, trong đó mức thấp nhất (như 'Poor' hoặc 'None') hay 'Female' đối với giới tính được chọn làm nhóm cơ sở (baseline). Bảng 9 minh họa một phần dữ liệu sau khi đã được tiền xử lý.


Bảng 9: Trích xuất một phần dữ liệu sau khi mã hóa (10 quan sát đầu tiên)

age	gender	study_hours_per_day	social_media_hours	netflix_hours	part_time_job
23	Female	0.0	1.2	1.1	No
20	Female	6.9	2.8	2.3	No
21	Male	1.4	3.1	1.3	No
23	Female	1.0	3.9	1.0	No
19	Female	5.0	4.4	0.5	No
24	Male	7.2	1.3	0.0	No
21	Female	5.6	1.5	1.4	Yes
21	Female	4.3	1.0	2.0	Yes
23	Female	4.4	2.2	1.7	No
18	Female	4.8	3.1	1.3	No

Đánh giá ngoại lai thông qua biểu đồ Boxplot (Hình 13) cho thấy hầu hết các biến định lượng không có ngoại lai nghiêm trọng. Các điểm ngoại lai nhỏ lẻ (ví dụ số giờ học quá cao hoặc điểm thi quá thấp) đều phản ánh biến dị hợp lệ trong thực tế giáo dục. Do đó, toàn bộ 1000 quan sát được giữ nguyên. Biểu đồ phân tán (Scatter plot - Hình 12) cho thấy biến `study_hours_per_day` thể hiện xu hướng tuyến tính dương rất rõ rệt với điểm thi.



Hình 12: Biểu đồ phân tán giữa thói quen sinh hoạt và điểm thi.



Hình 13: Phân phối Boxplot của các thói quen sinh hoạt và điểm thi.

4.2.2 Lựa chọn Phương pháp (Method Selection)

Để giải quyết 3 câu hỏi nghiên cứu đã đặt ra ở **Phần 1.2**, các phương pháp Thống kê Nhiều chiều được lựa chọn tương ứng bao gồm:

- **MANOVA:** Trả lời Câu hỏi 1 thông qua kiểm định sự khác biệt của trung bình vector đa biến.
- **Hồi quy Tuyến tính Đa chiều (Multivariate Linear Regression):** Trả lời Câu hỏi 2 bằng cách ước lượng đồng thời ma trận hệ số cho 3 biến phụ thuộc.
- **Phân cụm K-Means:** Trả lời Câu hỏi 3 dựa trên các đặc trưng hành vi không giám sát.

4.2.3 Kiểm tra các Giả định và Tính phù hợp của Dữ liệu


Ma trận Tương quan Spearman

Về mặt lý thuyết, KMO và Bartlett được xây dựng dựa trên ma trận tương quan Pearson với giả định phân phối chuẩn liên tục; với dữ liệu hỗn hợp chứa biến thứ bậc, không có phương án nào hoàn toàn đúng chuẩn- Pearson vi phạm giả định về bản chất biến, Spearman chưa có nền tảng lý thuyết chính thức khi dùng làm input cho KMO/Bartlett, còn ma trận polychoric/polyserial đòi hỏi giả định về biến liên tục tiềm ẩn phía sau các biến thứ bậc. Nhóm chọn Spearman như một thỏa hiệp thực dụng, chấp nhận đây là giới hạn phương pháp luận.

Kết quả ma trận tương quan Spearman (Hình 14) cho thấy:

- **Giữa các biến độc lập với nhau:** Tất cả các hệ số tương quan cặp giữa các biến thói quen sinh hoạt đều rất gần 0 (không có cặp nào vượt ngưỡng $|r| > 0.20$). Đây là dấu hiệu **không có đa cộng tuyến nghiêm trọng** - điều kiện thuận lợi cho Multivariate LR.
- **Giữa các biến độc lập và exam_score:** `study_hours_per_day` có tương quan dương rất mạnh ($r \approx 0.82$). `mental_health_rating` ($r \approx 0.32$) có tương quan dương ở mức trung bình; `exercise_frequency` ($r \approx 0.15$) có tương quan dương yếu. `social_media_hours` ($r \approx -0.17$) và `netflix_hours` ($r \approx -0.17$) có tương quan âm nhẹ. Các biến còn lại có tương quan rất yếu - tuy nhiên, chúng vẫn được giữ lại trong mô hình để đóng vai trò biến kiểm soát.

Ma trận tương quan Spearman



Hình 14: Ma trận tương quan Spearman giữa các biến định lượng và thứ bậc.

Kiểm tra Giả định MANOVA

Mô hình đánh giá yếu tố làm thêm (Yes/No) và ngoại khóa (Yes/No) trên vector 3 biến Y.

- **Box's M Test:** Để đánh giá giả định đồng nhất ma trận hiệp phương sai giữa các nhóm, kiểm định Box's M được thực hiện với các giả thuyết:

- H_0 : Ma trận hiệp phương sai của Y đồng nhất giữa 4 tổ hợp nhóm ($\Sigma_1 = \Sigma_2 = \Sigma_3 = \Sigma_4$).
- H_1 : Tồn tại ít nhất một cặp nhóm có ma trận hiệp phương sai khác nhau.


Kết quả $p = 0.7305 > 0.05$, do đó không có bằng chứng bác bỏ H_0 . Giả định đồng nhất được thỏa mãn.

- **Ngoại lai Mahalanobis đa chiều:** Không phát hiện quan sát ngoại lai nào (Số lượng = 0).
- **Tương quan giữa các biến phản hồi (Y):** Kiểm tra hệ số tương quan giữa 3 biến phụ thuộc (Bảng 10). Các hệ số tương quan nhìn chung ở mức thấp đến trung bình ($|r| < 0.4$), đảm bảo các biến phụ thuộc có mối liên hệ nhưng không bị đa cộng tuyến.
- **Phân phối chuẩn đa biến:** Biểu đồ Q-Q Plot đơn biến (Hình 15) cho thấy exam_score và attendance_percentage bám khá sát đường tham chiếu trên phần

lớn dải quan sát, cho thấy xấp xỉ chuẩn tốt ở vùng trung tâm. Xuất hiện hiện tượng lệch nhẹ ở đuôi dưới, phản ánh một số quan sát có điểm rất thấp. Riêng `mental_health_rating` thể hiện dạng bậc thang đặc trưng của biến rời rạc nguyên (thang 1–10), không phải vi phạm chuẩn thực sự. Với cỡ mẫu $n = 1000$, Định lý Giới hạn Trung tâm (CLT) đảm bảo tính vững của kiểm định.

Bảng 10: Tương quan Spearman giữa các biến phản hồi

Part-time job	Extracurricular	n	r(exam, mental)	r(exam, attend)	r(mental, attend)
No	No	531	0.346	0.104	0.031
No	Yes	254	0.335	0.067	0.005
Yes	No	151	0.240	0.121	-0.075
Yes	Yes	64	0.285	0.108	-0.209



Hình 15: Biểu đồ Q-Q Plot kiểm tra phân phối chuẩn của các biến mục tiêu.

Chú thích: Nhóm nhận thức rõ tính chuẩn đơn biến không đảm bảo tính chuẩn đa biến đồng thời. Tuy nhiên, thay vì phụ thuộc vào các kiểm định phân phối chuẩn đa biến (vốn quá nhạy cảm với cỡ mẫu lớn và dễ bị nhiễu), nghiên cứu dựa trên Định lý Giới hạn Trung tâm với $n = 1000$ kết hợp với biểu đồ Q-đơn biến. Cỡ mẫu lớn đảm bảo các thống kê kiểm định MANOVA (như Wilks’ Lambda) đạt được tính bền vững cần thiết, ngay cả khi dữ liệu vi phạm giả định phân phối chuẩn.

Đánh giá tính phù hợp của PCA/EFA

Để đánh giá khả năng rút gọn chiều dữ liệu (Dimensionality Reduction) và trích xuất nhân tố tiềm ẩn, nhóm nghiên cứu đã tiến hành kiểm tra cấu trúc của ma trận tương quan Spearman trên toàn bộ các biến số:

- **Chỉ số KMO (Kaiser-Meyer-Olkin):** Kết quả đo lường mức độ thích hợp của mẫu (MSA) tổng thể chỉ đạt 0.50, và MSA của từng biến đơn lẻ đều xoay quanh mức rất thấp (từ 0.48 đến 0.52). Trong phân tích nhân tố, KMO thường được yêu cầu đạt tối thiểu 0.6 để đảm bảo các biến chia sẻ đủ lượng phương sai (shared variance). Giá trị 0.50 phản ánh mức độ tương quan riêng phần giữa các biến là quá yếu, không phù hợp để gom nhóm.

Bảng 11: Chỉ số MSA (Measure of Sampling Adequacy) cho từng biến

Biến số	MSA	Biến số	MSA
Age	0.51	Sleep hours	0.50
Gender	0.50	Exercise frequency	0.52
Study hours per day	0.52	Mental health rating	0.50
Social media hours	0.50	Diet quality	0.49
Netflix hours	0.48	Parental education	0.52
Attendance percentage	0.51	Internet quality	0.51

- **Kiểm định Bartlett's Test of Sphericity:** Kiểm định cho ra giá trị $\chi^2(66) = 47.72$ với mức ý nghĩa $p = 0.956 > 0.05$. Điều này có nghĩa là dữ liệu không cung cấp đủ bằng chứng để bác bỏ giả thuyết H_0 (giả thuyết cho rằng ma trận tương quan tổng thể là ma trận đơn vị). Về mặt thống kê, điều này khẳng định các biến trong bộ dữ liệu gần như trực giao (độc lập tuyến tính) với nhau.

Kết luận: Việc các thói quen sinh hoạt (như giờ ngủ, tập thể dục, dùng mạng xã hội) mang tính độc lập cao là một lợi thế cực lớn cho các mô hình Phân tích Phương sai và Hồi quy sau này vì nó giúp loại trừ triệt để nguy cơ đa cộng tuyến (multicollinearity). Tuy nhiên, chính đặc tính này lại làm cho việc áp dụng PCA hay EFA trở nên vô nghĩa, bởi không tồn tại cấu trúc dữ liệu tiềm ẩn nào để tóm tắt. Do đó, nghiên cứu **quyết định bác bỏ phương pháp PCA/EFA** đối với tập dữ liệu này và giữ nguyên các chiều dữ liệu gốc để đưa vào MANOVA, Multivariate LR, và K-Means.

4.2.4 Thực hiện Phân tích các Mô hình (Model Estimation)

Trong cả hai phương pháp Phân tích Phương sai Đa biến (MANOVA) và Hồi quy Tuyến tính Đa biến (Multivariate LR) dưới đây, nghiên cứu sử dụng phương pháp **Kiểm định Tổng thể (Omnibus Test)** dựa trên tiêu chuẩn Wilks' Λ . Phương pháp này đánh giá sự phù hợp của mô hình thông qua việc so sánh hai kịch bản:

- **Mô hình Null (Null Model - Mô hình rỗng):** Là mô hình cơ sở (baseline) hoàn toàn không chứa bất kỳ biến độc lập nào, chỉ chứa duy nhất hằng số (Intercept). Điều này đồng nghĩa với việc toàn bộ hệ số tác động $\mathbf{B} = 0$. Mô hình Null đại diện cho giả thuyết H_0 : Các yếu tố/thói quen sinh hoạt hoàn toàn không tạo ra bất kỳ sự khác biệt hay tác động nào lên kết quả của sinh viên.
- **Mô hình Full (Full Model - Mô hình đầy đủ):** Là mô hình được đưa vào toàn bộ các biến độc lập cần xem xét (ví dụ: làm thêm và ngoại khóa trong MANOVA, hoặc toàn bộ 12 thói quen sinh hoạt trong MLR). Mô hình Full đại diện cho giả thuyết H_1 : Các biến độc lập có chứa thông tin hữu ích và thực sự tác động lên vector biến phụ thuộc.

Việc kiểm định Omnibus (so sánh Full Model với Null Model) giúp trả lời câu hỏi cốt lõi: Liệu việc đưa các biến thói quen sinh hoạt vào có giúp dự báo kết quả của sinh viên tốt hơn một cách có ý nghĩa thống kê so với việc phỏng đoán mù mờ (chỉ dùng giá trị trung bình của Null Model) hay không?

1. Phân tích phương sai đa biến (MANOVA)

Nhóm tiến hành kiểm định tổng thể (Omnibus Test) so sánh mô hình đầy đủ với mô hình rỗng thông qua Wilks' Λ :

- H_0 : `part_time_job`, `extracurricular_participation` và tương tác của chúng không tạo khác biệt có ý nghĩa trên vector $\mathbf{Y}$ ($\mathbf{B} = 0$).
- H_1 : Ít nhất một hiệu ứng (chính hoặc tương tác) tạo khác biệt có ý nghĩa thống kê trên vector $\mathbf{Y}$.

Bảng 12: Kết quả kiểm định Omnibus MANOVA (Wilks' Λ)

Mô hình	Res.Df	Wilks	Approx F	Num Df	Den Df	Pr(>F)
1 (Null)	999	-	-	-	-	-
2 (Full)	996	0.9888	1.248	9	2419.3	0.2608

Kiểm định cho kết quả Wilks' $\Lambda = 0.989$, $F(9, 2419.3) = 1.248$, $p = 0.261 > 0.05$ (bảng ANOVA đầy đủ xem Phụ lục A.5). Như vậy, dữ liệu không cung cấp đủ bằng chứng thống kê để MANOVA kết luận rằng hai yếu tố này tạo ra sự khác biệt có hệ thống. Trong bộ dữ liệu với $n = 1000$ sinh viên — cỡ mẫu đủ lớn để phát hiện các hiệu ứng nhỏ nếu chúng tồn tại thực sự - mô hình MANOVA không ghi nhận bất kỳ sự phân hóa đa chiều nào có ý nghĩa thống kê giữa bốn tổ hợp nhóm. Điều này gợi ý rằng với cỡ mẫu và thiết kế nghiên cứu hiện tại, hai yếu tố phân loại này không phải là nhân tố giải thích trọng tâm cho sự khác biệt về kết quả sinh viên.

Theo nguyên tắc kiểm định thứ bậc được khuyến nghị bởi Tabachnick & Fidell (2013), khi kiểm định Omnibus không đạt ý nghĩa thống kê, nghiên cứu không tiến hành diễn giải các hiệu ứng đơn lẻ (main effects, interaction) như những phát hiện có ý nghĩa thực tiễn. Dù việc chạy thêm kiểm định Type III cho từng effect về mặt kỹ thuật không làm tăng sai lầm loại I nếu chỉ dùng để mô tả cấu trúc dữ liệu, nhóm quyết định không thực hiện bước này nhằm tránh rủi ro diễn giải quá mức một kết quả omnibus đã không đạt ngưỡng ý nghĩa. Cách tiếp cận này nhất quán với việc omnibus của MLR ở phần sau có ý nghĩa thống kê nên mới tiến hành Type III đầy đủ — tức tiêu chí quyết định là kết quả omnibus, không phải bản chất của kiểm định Type III.

2. Mô hình Hồi quy Tuyến tính Đa biến (Multivariate LR)

Theo Johnson & Wichern (2007, Ch.7), Multivariate Linear Regression ước lượng đồng thời ma trận hệ số $\mathbf{B} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ với $\mathbf{Y}$ là ma trận $n \times 3$. Để đánh giá mức độ phù hợp tổng thể của mô hình theo nguyên tắc kiểm định thứ bậc, nhóm tiến hành so sánh mô hình đầy đủ với mô hình rỗng (chỉ chứa Intercept) thông qua kiểm định Wilks' Λ .

Bảng 13: Kết quả kiểm định Omnibus Multivariate LR (Wilks' Λ)

Mô hình	Res.Df	Wilks	Approx F	Num Df	Den Df	Pr(>F)
1 (Null)	999	-	-	-	-	-
2 (Full)	982	0.1056	64.545	51	2918.4	$< 2.2 \times 10^{-16}$ ***

Kết quả Omnibus Test xác nhận mô hình MLR tổng thể có ý nghĩa thống kê ($p < 0.01$). Tiếp theo, kiểm định Wilks' Λ theo từng predictor (Type III) được thực hiện để xác định biến nào đóng góp đáng kể vào sức giải thích của mô hình.

Mặc dù MANOVA và Multivariate LR cùng xuất hiện `part_time_job` và `extracurricular_participation` hai kiểm định này trả lời hai câu hỏi khác nhau về bản chất:

Bảng 14: So sánh bản chất kiểm định giữa MANOVA và MLR

Tiêu chí	MANOVA	Type III Wilks' Λ trong MLR
Mô hình	Chỉ có hai yếu tố phân loại	Có thêm các biến còn lại
Câu hỏi	Làm thêm/ngoại khóa có tạo khác biệt không, xét độc lập?	Sau khi đã tính đến toàn bộ thói quen sinh hoạt, hai yếu tố này còn đóng góp thêm gì không?
Ý nghĩa thực tiễn	Tác động biên	Tác động tăng thêm

Ghi chú: Nếu kết quả giữa hai phương pháp có sự khác biệt, đó không phải là mâu thuẫn, mà là bằng chứng cho thấy sức mạnh giải thích của các biến phân loại chỉ được bộc lộ khi

đặt chúng trong cùng một mô hình hệ thống với các thói quen sinh hoạt khác.

Với mỗi hiệu ứng, cặp giả thuyết được phát biểu như sau:

Hiệu ứng chính `part_time_job`:

- H_0 : β của `part_time_job` = 0 trên cả ba phương trình (đã kiểm soát các biến còn lại).
- H_1 : Tồn tại ít nhất một phương trình có β của `part_time_job` $\neq 0$.

Hiệu ứng chính `extracurricular_participation`:

- H_0 : β của `extracurricular_participation` = 0 trên cả ba phương trình (đã kiểm soát các biến còn lại).
- H_1 : Tồn tại ít nhất một phương trình có β của `extracurricular_participation` $\neq 0$.

Hiệu ứng tương tác `part_time_job` $\times$ `extracurricular_participation`:

- H_0 : β của tương tác `part_time_job` $\times$ `extracurricular_participation` = 0 trên cả ba phương trình.
- H_1 : Tồn tại ít nhất một phương trình có β của tương tác $\neq 0$.

Bảng 15: Kết quả kiểm định Type III MANOVA (Wilks' Λ) cho mô hình MLR

Biến độc lập	Df	Wilks	Approx F	Num Df	Den Df	Pr(>F)
(Intercept)	1	0.570	246.47	3	980.0	$< 2.2 \times 10^{-16}$ ***
age	1	0.997	0.99	3	980.0	0.3971
gender	2	0.999	0.24	6	1960.0	0.9644
study_hours_per_day	1	0.125	2281.51	3	980.0	$< 2.2 \times 10^{-16}$ ***
social_media_hours	1	0.751	108.33	3	980.0	$< 2.2 \times 10^{-16}$ ***
netflix_hours	1	0.824	69.73	3	980.0	$< 2.2 \times 10^{-16}$ ***
part_time_job	1	0.998	0.55	3	980.0	0.6474
sleep_hours	1	0.825	69.08	3	980.0	$< 2.2 \times 10^{-16}$ ***
diet_quality	2	0.988	1.98	6	1960.0	0.0656 .
exercise_frequency	1	0.767	99.44	3	980.0	$< 2.2 \times 10^{-16}$ ***
parental_education_level	3	0.975	2.76	9	2385.2	0.0033 **
internet_quality	2	0.993	1.19	6	1960.0	0.3094
extracurricular_participation	1	0.999	0.20	3	980.0	0.8981

Đánh giá đóng góp độc lập: Phân tích Type III Wilks' Λ phân tách mức độ đóng góp độc lập của từng biến dự báo sau khi đã kiểm soát toàn bộ các biến còn lại. Bảng 16 và 17 minh họa sức giải thích (R^2) và tác động đa chiều của các biến có ý nghĩa thống kê ($p < 0.01$).

Bảng 16: Sức giải thích của ba phương trình hồi quy

Biến phản hồi	R^2 hiệu chỉnh	Ghi chú
exam_score	0.788	Mức giải thích khá cao, cho thấy các thói quen sinh hoạt tác động mạnh đến điểm số.
attendance_percentage	0.007	Thấp - chịu tác động của nhiều yếu tố ngoài mô hình.
mental_health_rating	0.005	Thấp hơn đáng kể - ít bị quyết định bởi thói quen đơn thuần.

Bảng 17: Profile tác động đa chiều của các biến cốt lõi (β^*)

Biến độc lập (X)	$\beta^* \rightarrow \text{exam_score}$	$\beta^* \rightarrow \text{mental_health}$	$\beta^* \rightarrow \text{attendance}$
study_hours_per_day	+0.836	+0.002	+0.026
social_media_hours	-0.176	+0.003	+0.043
netflix_hours	-0.143	+0.006	+0.003
sleep_hours	+0.144	-0.007	+0.014
exercise_frequency	+0.171	-0.008	-0.007

- **Đóng góp cốt lõi** ($p < 0.001$): Các thói quen sinh hoạt vi mô (Bảng 17) mang tính quyết định. `study_hours` chi phối mạnh nhất đến điểm thi ($\beta^* = 0.836$), trong khi giải trí số (`social_media`, `netflix`) có tác động âm.
- **Đóng góp có ý nghĩa** ($p = 0.003 < 0.01$): Trình độ học vấn của phụ huynh (`parental_education_level`), phản ánh vai trò của nền tảng gia đình.
- **Không có ý nghĩa thống kê** ($p > 0.1$): Yếu tố làm thêm ($p = 0.647$) và ngoại khóa ($p = 0.898$) không có ý nghĩa thống kê, **tương đồng** với kết quả không đạt chuẩn từ mô hình MANOVA.

Kiểm tra giả định sau mô hình (Post-estimation diagnostics):

1. Đa cộng tuyến (VIF): Toàn bộ biến có $VIF \approx 1.00$, không có đa cộng tuyến (Bảng 18).

Lưu ý: Tất cả các biến đều có chỉ số VIF bằng 1, nghĩa là chúng không liên quan gì đến nhau. Trong đời sống thực, điều này rất khó xảy ra (ví dụ: người xem Netflix nhiều thường sẽ ngủ ít đi), xác nhận đây rất có thể là **dữ liệu nhân tạo**. Vì vậy, kết quả phân tích ở mức tốt, nhưng nghiên cứu cũng cần trọng khi mang những kết luận này áp dụng trực tiếp ra môi trường giáo dục thực tế.

Bảng 18: Tóm tắt chỉ số VIF của mô hình


Biến độc lập	GVIF	Df	GVIF^{1/(2Df)}
age	1.008	1	1.004
gender	1.031	2	1.008
study_hours_per_day	1.012	1	1.006
social_media_hours	1.008	1	1.004
netflix_hours	1.007	1	1.004
part_time_job	1.013	1	1.006
sleep_hours	1.010	1	1.005
diet_quality	1.023	2	1.006
exercise_frequency	1.013	1	1.006
parental_education_level	1.025	3	1.004
internet_quality	1.028	2	1.007
extracurricular_participation	1.008	1	1.004

2. Phương sai sai số đồng nhất (Breusch-Pagan Test): Cả 3 phương trình đều cho $p > 0.05$, không vi phạm giả định (Bảng 19).

Bảng 19: Kết quả kiểm định Breusch-Pagan cho ba phương trình

Phương trình	BP	df	p
exam_score	21.170	17	0.2188
mental_health_rating	15.760	17	0.5409
attendance_percentage	13.163	17	0.7252

3. Ngoại lai phần dư Mahalanobis: Phát hiện 3 quan sát vượt ngưỡng $\alpha = 0.001$, chiếm tỷ lệ siêu nhỏ (0.3%), giữ nguyên để phân tích. Biểu đồ Chi-square Q-Q Plot (Hình 16) xác nhận phần dư bám sát đường tham chiếu.



Hình 16: Biểu đồ Chi-square Q-Q Plot kiểm tra ngoại lai đa chiều.

4. Đặc tả hàm tuyến tính (Ramsey RESET Test): Phương trình `exam_score` vi phạm cực bộ ($p < 0.001$) do hiệu ứng trần (Bảng 20). Cụ thể, khi các giá trị dự báo của phương trình có $R^2 = 0.792$ tiến sát giới hạn trên (100 điểm) của thang đo, cấu trúc tuyến tính bị phá vỡ. Ngược lại, `mental_health_rating` ($p = 0.723$) và `attendance_percentage` ($p = 0.443$) không vi phạm, do biên độ dự báo hẹp chưa chạm ngưỡng cấu trúc của thang đo. Kết luận: Mô hình Multivariate LR không gặp rủi ro phi tuyến hệ thống; riêng `exam_score` cần thận trọng khi diễn giải ở nhóm có tần suất học tập cực đại (nơi quy luật hiệu suất giảm dần chi phối).


Bảng 20: Kết quả kiểm định Ramsey RESET

Phương trình	RESET	df1	df2	p
<code>exam_score</code>	14.471	2	980	6.00e-07
<code>mental_health_rating</code>	0.324	2	980	7.23e-01
<code>attendance_percentage</code>	0.816	2	980	4.43e-01

5. Đồ thị chẩn đoán phần dư (Residual Diagnostics): Nhóm nhận thức rõ tính chuẩn đơn biến không đảm bảo tính chuẩn đa biến đồng thời. Tuy nhiên, thay vì phụ thuộc vào các kiểm định phân phối chuẩn đa biến (vốn quá nhạy cảm với cỡ mẫu lớn và dễ bị nhiễu bởi các giá trị cực trị), nghiên cứu dựa trên Định lý Giới hạn Trung tâm với $n = 1000$ kết hợp với biểu đồ Q-Q đa biến. Cỡ mẫu lớn đảm bảo các thống kê kiểm định MANOVA (như Wilks' Lambda) đạt được tính bền vững cần thiết, ngay cả khi dữ liệu vi phạm giả định phân phối chuẩn.

Khảo sát chi tiết 4 đồ thị (của 3 phương trình) cho thấy:

- *Phân phối & Đặc tả (Q-Q, Residuals vs Fitted)*: Phần dư bám sát phân phối chuẩn ở vùng trung tâm. Hiện tượng lệch đuôi dưới ở `exam_score` và `attendance` (kèm hiệu ứng trần cực bộ ở vùng điểm > 90) phản ánh bản chất bị chặn giới hạn của thang đo điểm số, không gây sai lệch suy diễn nhờ Định lý Giới hạn Trung tâm ($n = 1000$).
- *Phương sai đồng nhất (Scale-Location)*: Đồ thị thể hiện độ tán xạ ổn định (ngoại trừ vùng điểm bị hiệu ứng trần), tương thích với kết quả không vi phạm của kiểm định Breusch-Pagan.
- *Điểm ảnh hưởng (Residuals vs Leverage)*: Tuyệt đối không có quan sát nào vượt ngưỡng Cook's $D > 0.5$. Các điểm có phần dư lớn (ví dụ obs. 30, 344) đều mang đòn bẩy (leverage) rất thấp, không có khả năng gây nhiễu ma trận hệ số hồi quy **B**.
- *Tương quan phần dư (Omitted Variable Bias)*: Tương quan phần dư giữa `exam_score` và `mental_health_rating` đạt mức $r = 0.706$ (vượt xa tương quan thô $r \approx 0.32$). Điều này cho thấy sau khi kiểm soát các biến X, hai biến này vẫn chia sẻ một phương sai chung rất lớn, minh chứng rõ rệt cho sự tồn tại của **biến ẩn** chi phối hệ thống.



Hình 17: Đồ thị chẩn đoán phần dư (Residual Diagnostics) cho ba phương trình hồi quy.

3. Phân nhóm sinh viên (K-Means Clustering)

Kết quả kiểm tra ban đầu với $k = 8$ cho thấy chỉ số Silhouette ở mức $0.153 (< 0.25)$, theo Kaufman & Rousseeuw (1990), điều này chỉ ra rằng tập dữ liệu không tồn tại một cấu trúc cụm tách biệt tự nhiên. Thay vì cố gắng khiến cưỡng phân mảnh dữ liệu thành nhiều nhóm thiếu cơ sở, nghiên cứu chuyển sang tiếp cận phân cụm theo hướng thực dụng: so sánh hệ thống các phương án $k = 2, 3, 4$ qua bốn chỉ số đánh giá (Bảng 21).

Khi so sánh $k = 2$ và $k = 3$, chỉ số Davies-Bouldin giảm từ 2.469 xuống 2.080 (giảm khoảng 15.8% - một mức cải thiện khá rõ rệt). Về mặt khoa học hành vi, cấu trúc 3 cụm luôn tạo ra một dải đối xứng: [Thấp - Trung bình - Cao] hoặc [Tiêu cực - Trung lập - Tích cực]. Cấu trúc này tinh tế hơn cấu trúc nhị phân chỉ có hai thái cực đối lập của $k = 2$. Do đó, nhóm lựa chọn phân tập dữ liệu thành 3 cụm.

Lưu ý: Chỉ số Hopkins $H \approx 1$ phản ánh dữ liệu có xu hướng phân cụm (tức là không

phân phối hoàn toàn đồng nhất ngẫu nhiên), nhưng không đảm bảo các cụm tách biệt rõ ràng. Silhouette = 0.131 xác nhận các cụm tồn tại nhưng có sự giao thoa lớn. Hai chỉ số đo hai khía cạnh khác nhau và không mâu thuẫn.

Bảng 21: So sánh các chỉ số đánh giá phân cụm theo số cụm k

k	WSS	Davies-Bouldin	Calinski-Harabasz	Silhouette
2	4291.0	2.469	163.7	0.137
3	3815.6	2.080	154.1	0.131
4	3446.5	1.854	149.2	0.135
8	2560.0	1.500	134.8	0.153

Kết quả phân cụm K-means ($k = 3$) đã trích xuất 3 profile hành vi đặc trưng [5] (Bảng 22):

1. **Cụm 1 - Nỗ lực cao (n=356):** Chiến lược học tập cường độ lớn (4.79 giờ), chấp nhận đánh đổi giấc ngủ (5.93 giờ) để tối đa hóa điểm thi (80.77 điểm).
2. **Cụm 2 - Trì hoãn (n=307):** Tiêu thụ truyền thông số (MXH, Netflix) cao nhất (5.16 giờ tổng cộng), thời lượng học thấp nhất (2.50 giờ), dẫn đến kết quả học tập (59.02 điểm) kém nhất.
3. **Cụm 3 - Cân bằng (n=337):** Thể hiện sự kỷ luật trong việc hạn chế màn hình, duy trì thời gian học và ngủ hợp lý, từ đó đạt được mức điểm khá (67.45) cùng trạng thái tinh thần tốt nhất.

Bảng 22: Thống kê mô tả (Profile) của các cụm K-Means (k=3)

Cluster	Số lượng	Học tập (h/ngày)	MXH (h/ngày)	Netflix (h/ngày)	Ngủ (h/ngày)	Vận động (lần/tuần)	Điểm thi TB
1	356	4.79	2.66	1.65	5.93	3.01	80.77
2	307	2.50	3.08	2.08	7.03	3.05	59.02
3	337	3.20	1.82	1.76	6.53	3.07	67.45

Để kiểm định xem điểm thi có phân hóa có ý nghĩa thống kê giữa 3 cụm hành vi hay không, kiểm định One-way ANOVA được thực hiện ($H_0 : \mu_1 = \mu_2 = \mu_3$). Kết quả ANOVA tổng thể xác nhận điểm thi trung bình khác biệt có ý nghĩa thống kê giữa 3 cụm ($F(2, 997) = 195.7, p < 0.001$).

Vì ANOVA chỉ xác nhận tồn tại sự khác biệt, kiểm định hậu nghiệm Tukey HSD được thực hiện để so sánh từng cặp (Bảng 23). Kết quả cho thấy cả 3 cặp đều có chênh lệch ý nghĩa thống kê ($p < 0.001$). Lớn nhất là chênh lệch giữa cụm Nỗ lực cao và Trì hoãn (21.75 điểm).

Bảng 23: Chênh lệch điểm thi trung bình giữa các cụm (Tukey HSD)

Cặp so sánh	Chênh lệch điểm thi	p
Cụm 1 (Nỗ lực cao) vs Cụm 2 (Trì hoãn)	21.75	< 0.001
Cụm 1 (Nỗ lực cao) vs Cụm 3 (Cân bằng)	13.31	< 0.001
Cụm 3 (Cân bằng) vs Cụm 2 (Trì hoãn)	8.43	< 0.001

4.2.5 Tổng hợp kết quả Phần 2 (Cross-Method Synthesis)

Đặt ba phương pháp cạnh nhau, một thông điệp đồng nhất xuất hiện: thời gian tự học là nhân tố chi phối mạnh nhất đối với điểm thi trong bộ dữ liệu này. Multivariate LR xác nhận điều này qua $\beta^* = 0.836$ - một hệ số chuẩn hóa bất thường cao, cho thấy `study_hours_per_day` một mình giải thích phần lớn $R^2 = 0.792$. K-Means xác nhận lại thông qua con đường không giám sát: các cụm được phân chia chủ yếu theo `study_hours`, và điểm thi phân hóa thuận chiều. MANOVA bổ sung một chiều thông tin quan trọng bằng cách loại trừ: việc đi làm thêm và ngoại khóa - hai yếu tố mà trực giác thông thường cho là "phân tán không có đủ bằng chứng thống kê để kết luận tác động có hệ thống lên vector kết quả sinh viên.

Tuy nhiên, sự đồng thuận giữa ba phương pháp cũng bộc lộ một giới hạn chung: cả ba đều bị chi phối bởi `study_hours` như một biến trội, và đều yếu trong việc giải thích `mental_health_rating` và `attendance_percentage`. Điều này không phải lỗi của phương pháp mà là thông tin về bộ dữ liệu: các thói quen sinh hoạt đo được trong bộ dữ liệu này không phải nhân tố quyết định chủ yếu của sức khỏe tâm thần và tỷ lệ chuyên cần - hai chiều quan trọng của kết quả sinh viên vẫn còn chủ yếu chưa được giải thích bởi bất kỳ phương pháp nào trong ba phương pháp đã áp dụng.


4.2.6 Tổng kết Phần 2 (Conclusion)

Đối với hệ sinh thái hành vi của sinh viên, chuỗi phương pháp phân tích đã đưa ra lời giải đáp định lượng cho cả ba câu hỏi nghiên cứu. Trước tiên, kiểm định MANOVA cho thấy việc tham gia thị trường lao động sớm hay hoạt động ngoại khóa không tạo ra sự biến động có ý nghĩa thống kê lên cấu trúc thành quả học tập và tinh thần tổng thể. Thứ hai, dưới lăng kính Hồi quy Tuyến tính Đa biến, thời gian tự học nổi lên như nhân tố chi phối độc tôn, định hình trực tiếp điểm số học thuật nhưng lại có ít tác động đến tỷ lệ chuyên cần hay sức khỏe tâm thần. Cuối cùng, thuật toán Học máy Không giám sát K-Means đã nhận diện thành công ba nhóm hành vi sinh viên điển hình: "Nỗ lực cao", "Trì hoãn" và "Cân bằng". Các nhóm này không chỉ thể hiện sự phân hóa rõ rệt về thói quen phân bổ thời gian mà còn dẫn đến sự chênh lệch có ý nghĩa thống kê về điểm thi. Qua đó, nghiên cứu khẳng định khả năng bóc tách cấu trúc hành vi vi mô và lượng hóa hệ quả học thuật của các phương pháp thống kê xã hội học.

4.3 Phần 3: Dự báo Suy thoái Động cơ Máy bay C-MAPSS

4.3.1 Khám phá Đặc trưng Cơ học (EDA)


Dữ liệu C-MAPSS FD001 bao gồm 21 cảm biến đo lường các thông số nhiệt động học của động cơ phản lực qua từng chu kỳ hoạt động cho đến khi hỏng hóc (Run-to-Failure) [1]. Việc trực quan hóa tín hiệu thô (Hình 18) cho thấy sự suy thoái vật lý bị che khuất phần lớn dưới lớp nhiễu (noise) tần số cao. Điều này đòi hỏi phải có kỹ thuật lọc tín hiệu phù hợp.



Hình 18: Tín hiệu thô của 4 cảm biến tiêu biểu (Động cơ #1). Xu hướng suy thoái bị nhiễu che lấp.

Việc phân tích ma trận tương quan (Hình 19) kết hợp với quan sát tín hiệu thô giúp ta rút ra 2 kết luận vật lý mang tính nền tảng cho toàn bộ hệ thống mô hình phía sau:

- **Đặc tính nhiễu động học cao:** Nếu đưa trực tiếp dữ liệu thô vào các thuật toán dự báo, sai số sẽ bị khuếch đại đáng kể. Do đó, việc áp dụng **Bộ lọc Kalman** để ước lượng trạng thái thực (True State) của động cơ là một bước đi cần thiết.
- **Đa cộng tuyến (Multicollinearity):** Rất nhiều cảm biến (như S4, S11, S12) có tương quan tuyến tính chặt chẽ, cùng phản ánh một xu hướng hao mòn chung. Việc sử dụng trực tiếp hồi quy bội (MLR) dễ dẫn đến hiện tượng quá khớp (overfitting). Nén chiều bằng **Phân tích Thành phần Chính (PCA)** là giải pháp toán học giúp hạn chế sự dư thừa thông tin này [2].




Hình 19: Ma trận Tương quan: Mức độ tương quan rất cao chứng tỏ sự tồn tại của Đa cộng tuyến.

4.3.2 Tiền xử lý Dữ liệu (Data Preprocessing)

1. Đánh giá Thang đo và Chuẩn hóa Dữ liệu (Min-Max Scaling)


Quá trình tiền xử lý bắt đầu bằng việc loại bỏ 7 cảm biến tĩnh (không có phương sai) và giữ lại 14 cảm biến cốt lõi. Đặc biệt, biến mục tiêu là vòng đời còn lại (RUL) được giới hạn tối đa ở mức 125 chu kỳ (Piece-wise Linear RUL), phản ánh thực tế vật lý rằng động cơ hoạt động ổn định và không suy thoái trong giai đoạn đầu.

Tuy nhiên, khi quan sát phân phối dữ liệu gốc của 14 cảm biến này (Hình 20), ta có thể thấy một sự chênh lệch khổng lồ về mặt thang đo (scale). Ví dụ, cảm biến S9 dao động ở mức gần 9000, trong khi S11 hay S15 chỉ ở mức hàng đơn vị hoặc thập phân. Sự chênh lệch này là điều tối kỵ đối với thuật toán Phân tích Thành phần Chính (PCA), vì PCA hoạt động dựa trên phương sai; biến nào có thang đo lớn sẽ áp đảo hoàn toàn các biến khác dù chưa chắc chúng đã mang nhiều thông tin suy thoái hơn.



Hình 20: Phân phối dữ liệu gốc của 14 Cảm biến: Sự chênh lệch khổng lồ về thang đo đòi hỏi phải chuẩn hóa.

Do đó, việc chuẩn hóa dữ liệu là bắt buộc. Toàn bộ 14 cảm biến đã được chuẩn hóa Min-Max để đưa về cùng một hệ quy chiếu $[0, 1]$. Biểu đồ Boxplot (Hình 21) biểu diễn sự phân tán của các cảm biến sau khi chuẩn hóa. Có thể thấy, dù tất cả các biến đã được nén vào dải $[0, 1]$, phân phối của chúng mang đặc trưng rất khác nhau: các cảm biến như S7, S12, S20, S21 có trung vị khá cao, trong khi các cảm biến như S9, S14 bị dồn nén với khoảng tứ phân vị (IQR) rất hẹp và xuất hiện hàng loạt điểm ngoại lai ở đuôi trên hoặc dưới. Sự khác biệt hình thái dồn dập này phản ánh quỹ đạo suy thoái cơ học phi tuyến phức tạp của động cơ máy bay.




Hình 21: Biểu đồ Boxplot phân tán của 14 cảm biến sau khi chuẩn hóa Min-Max.

2. Loại nhiễu tín hiệu: Kalman Filter vs Moving Average

Đặc trưng của dữ liệu cảm biến hàng không là chứa rất nhiều nhiễu tần số cao (white noise) sinh ra do rung động cơ học và độ trễ phản hồi cảm biến. Nếu đưa trực tiếp tín hiệu thô vào mô hình dự báo, nhiễu sẽ đánh lừa thuật toán và làm sai lệch quỹ đạo suy thoái thực sự.

Hai phương pháp lọc đã được đưa ra đối chiếu: Moving Average (MA) và Bộ lọc Kalman (Kalman Filter). Như thể hiện ở Hình 22, bộ lọc Moving Average (của số $w = 30$) tuy dễ triển khai và làm mịn được dữ liệu, nhưng lại gây ra hiện tượng "**trễ pha**" (**Lag**) nghiêm trọng. Trong bối cảnh bảo trì hàng không, việc dự báo trễ quỹ đạo suy thoái một vài chu kỳ bay có thể dẫn đến thảm họa.

Ngược lại, **Bộ lọc Kalman 1 chiều (1D Kalman Filter)** được lựa chọn vì nó là bộ ước lượng phù hợp (suitable estimator) cho hệ thống nhiễu Gauss. Với cơ chế vòng lặp *Dự đoán - Cập nhật (Predict-Update)*, bộ lọc Kalman liên tục tính toán độ bất định để tự động cân bằng giữa trạng thái dự báo và tín hiệu đo lường thực tế. Nhờ vậy, Kalman Filter không những khử nhiễu hiệu quả mà còn **bám sát thời gian thực (zero-lag tracking)** quỹ đạo suy thoái của động cơ, tạo ưu thế rõ rệt cho hệ thống cảnh báo sớm.




Hình 22: So sánh hiệu quả lọc nhiễu trên Cảm biến S4: Kalman Filter khử nhiễu bám sát thực tế, trong khi Moving Average bị trễ pha.

3. Kiểm định Phân phối Chuẩn Nhiều chiều (Mardia's Test)

Vì các thuật toán ở giai đoạn sau như Phân tích Thành phần Chính (PCA) và Mô hình Hỗn hợp Gauss (GMM) đều dựa trên giả định cơ sở về phân phối chuẩn, nghiên cứu đã tiến hành kiểm định Mardia (đo lường độ xiên - Skewness và độ nhọn - Kurtosis đa chiều) trên tập dữ liệu đã qua lọc Kalman (lấy mẫu ngẫu nhiên 2000 quan sát để tối ưu hóa khối lượng tính toán).

Kết quả định lượng từ kiểm định Mardia cho thấy cả độ xiên (Skewness = 15948.09, $p < 0.001$) và độ nhọn (Kurtosis = 168.79, $p < 0.001$) đều có giá trị thống kê rất lớn, bác bỏ giả thuyết H_0 về phân phối chuẩn đa chiều. Biểu đồ Normal Q-Q Plot (Hình 23) trực quan hóa độ phù hợp của dữ liệu với phân phối chuẩn đa biến. Có thể thấy rõ, mặc dù phần thân dữ liệu (nằm trong khoảng phân vị lý thuyết từ -2 đến 2) bám khá sát đường thẳng tham chiếu, khu vực đuôi trên (upper tail) lại bẻ cong và vọt lên rất cao (giá trị phân vị mẫu chạm mức 20). Sự sai lệch đáng kể ở phần đuôi này (heavy-tailed distribution) phản ánh sự tồn tại của các điểm dị thường và giai đoạn suy thoái cực đoan (khi động cơ sát ngưỡng hỏng hóc).

Kết quả này cho thấy hệ thống C-MAPSS **vi phạm giả định phân phối chuẩn đa chiều**. Tuy nhiên, đây là đặc tính vật lý tất yếu của dữ liệu chạy đến lúc hỏng (run-to-failure). Sự lệch chuẩn này sẽ dẫn tới hệ quả cơ học: khi áp dụng PCA, trục tọa độ sẽ có xu hướng xoay để thu thập các phương sai cực đoan này, và khi áp dụng GMM, thuật toán sẽ phải huy động thêm các cụm (components) riêng biệt để bao phủ vùng đuôi thay vì chỉ 1 cụm chuẩn đơn giản.



Hình 23: Biểu đồ Normal Q-Q Plot từ kiểm định Mardia: Đuôi trên lệch chuẩn nghiêm trọng, phản ánh quá trình suy thoái cực đoan.

4.3.3 Kiểm định Giả định Thống kê và Lựa chọn Số lượng Thành phần Chính

1. Kiểm định KMO và Bartlett's Test


Kiểm định trên tập Train được thực hiện nhằm kiểm tra sự hiện diện của hiện tượng "Đa cộng tuyến" và đánh giá mức độ phù hợp của dữ liệu trước khi chạy thuật toán nén chiều PCA. Đối với kiểm định Bartlett, ta có:

- H_0 : Ma trận tương quan của tổng thể là ma trận đơn vị.
- H_1 : Ma trận tương quan của tổng thể khác ma trận đơn vị.

Kết quả cho thấy **Kiểm định Bartlett** (Bartlett's Test of Sphericity) có p -value $< 2.2 \times 10^{-16} \approx 0$, bác bỏ giả thuyết không (H_0). Điều này chỉ ra rằng các biến cảm biến có sự tương quan tuyến tính rất chặt chẽ với nhau. Bên cạnh đó, chỉ số **KMO Overall** đạt mức rất cao 0.961 (lớn hơn rất nhiều so với ngưỡng 0.8), vượt xa yêu cầu tối thiểu. Hai chỉ số này cung cấp bằng chứng thống kê vững chắc để cho thấy tập dữ liệu C-MAPSS rất phù hợp để thực hiện giảm chiều bằng PCA.

2. Lựa chọn số lượng PC tối ưu bằng Screeplot và Parallel Analysis

Để quyết định số lượng Thành phần chính (PC) cần giữ lại, phương pháp cơ bản nhất là sử dụng biểu đồ Screeplot (Hình 24). Biểu đồ cho thấy PC_1 đóng vai trò chủ đạo khi giải thích tới 79.4% sự biến thiên của toàn bộ hệ thống 14 cảm biến, tạo thành một điểm "gãy" (elbow) rõ rệt.




Hình 24: Biểu đồ Screeplot: PC_1 chiếm tỷ trọng lớn với 79.4% phương sai giải thích.

Để tăng tính khách quan toán học thay vì chỉ quan sát Screeplot bằng mắt thường, phương pháp **Parallel Analysis** (Hình 25) tiếp tục được áp dụng. Phương pháp này so sánh trực tiếp Trị riêng thực tế (Actual Eigenvalues) của dữ liệu với Trị riêng giả lập (Simulated/Resampled Eigenvalues) từ mô phỏng Monte Carlo ngẫu nhiên. Qua đó, giúp xác định khách quan chính xác bao nhiêu PC thực sự mang thông tin có ý nghĩa lớn hơn yếu tố nhiễu ngẫu nhiên.

Dựa trên nguyên tắc chỉ giữ lại các PC có đường màu xanh (Actual Data) nằm phía trên đường đứt nét màu đỏ (Simulated Data), Parallel Analysis đề xuất giữ lại đúng **2 Thành phần chính (2 PCs)**.


Mặc dù thuật toán đề xuất giữ 2 PC, việc triển khai các thành phần này ở những bài toán tiếp theo được phân tách rõ ràng dựa trên hệ quả cơ học: PC_1 (chứa 79.4% phương sai) mang tính đơn điệu (monotonic) rất cao, phản ánh trực tiếp quỹ đạo hao mòn tự nhiên, do đó được chọn làm **Chỉ số Sức khỏe cốt lõi (Health Index)** duy nhất để dự báo đường cong RUL. Trong khi đó, các pha chuyển trạng thái vận hành bất thường của động cơ (như rung lắc đột ngột) lại cần quan sát ở nhiều góc độ hơn. Vì vậy, PC_1 , PC_2 (và có thể cả PC_3) sẽ được kết hợp lại để tạo không gian đa chiều, phục vụ riêng cho thuật toán Phân cụm Phát hiện Bất thường (GMM).



Hình 25: Parallel Analysis: Đối chiếu Eigenvalues thực tế và mô phỏng, đề xuất giữ lại 2 PC.

4.3.4 Trích xuất Chỉ số Sức khỏe bằng PCA và EFA


Việc trích xuất Thành phần chính được trực quan hóa thông qua Biểu đồ trọng số biến (PCA Variables - Hình 26) và Biểu đồ phân bố quan sát (PCA Individuals - Hình 27). Hai góc nhìn này có thể được kết hợp thành Biplot (Hình 28) để đánh giá đồng thời sự ảnh hưởng của từng cảm biến lên mỗi quan sát.




Hình 26: Trọng số các biến (Variables): Các vectơ cảm biến phân bố chủ yếu dọc theo trục PC_1 , chứng tỏ sự đóng góp lớn vào phương sai chung.

Đáng chú ý, trên biểu đồ phân bố quan sát (Hình 27), trục PC_1 (trục hoành) trải dài dữ liệu theo đúng sự chuyển màu của Vòng đời còn lại (RUL) từ trạng thái nguyên bản (màu xanh - RUL cao) đến trạng thái hỏng hóc (màu cam/đỏ - RUL thấp). Điều này một lần

nữa khẳng định bằng hình ảnh việc PC_1 đóng vai trò cốt lõi đại diện cho độ hao mòn cơ học của hệ thống.




Hình 27: Phân bố quan sát: Sự dịch chuyển tọa độ từ trái sang phải tương ứng với sự suy giảm RUL (màu xanh → cam/đỏ).



Hình 28: Biplot: Kết hợp quan sát và biến, thể hiện "lực kéo" của từng cảm biến lên xu hướng thoái hóa chung.

Phân tích chi tiết bằng biểu đồ cột Loadings (Hình 29) tiết lộ bản chất vật lý ngầm định mà thuật toán PCA đã "học" được từ dữ liệu:

- **PC_1 (Chỉ số Sức khỏe cốt lõi):** Các cảm biến liên quan mật thiết đến nhiệt độ và áp suất buồng đốt (như S4, S7, S11, S12, S15) đóng góp trọng số lớn. PCA đã nhận diện ra ranh giới tương quan vật lý thuận/ngịch (ví dụ: nhiệt độ tăng thì áp suất giảm) để gộp chúng thành một véc-tơ thoái hóa chung.
- **PC_2 (Biến thiên Vận hành):** Chiếm phần lớn trọng số từ cảm biến S9 và S14, phản ánh những dao động ngẫu nhiên hoặc các điều kiện vận hành chưa được lọc hết.
- **PC_3 (Nhiều Cục bộ):** Bị chi phối bởi các cảm biến ít liên quan trực tiếp đến mài mòn tổng thể.



Hình 29: Trọng số (Loadings) của 3 Thành phần chính đầu tiên: PC_1 (màu xanh lá) chiếm trọn sự chi phối từ đa số các cảm biến cốt lõi.

Mặc dù PCA đã thành công trong việc nén chiều và trích xuất PC_1 làm Chỉ số Sức khỏe, phương pháp này chủ yếu tối đa hóa tổng phương sai mà chưa phân tách rõ ràng các yếu tố cơ bản (latent factors) chi phối hệ thống. Để khắc phục điểm này và đi sâu hơn vào cấu trúc tiềm ẩn của dữ liệu, Phân tích Nhân tố Khám phá (EFA) với phương pháp Maximum Likelihood (ML) và phép xoay Varimax tiếp tục được thực hiện. Bảng 24 trình bày hệ số tải nhân tố (chỉ hiển thị các giá trị > 0.3).

Bảng 24: Ma trận Trọng số Nhân tố (Factor Loadings) từ EFA

Cảm biến	ML2	ML1
S2	0.931	
S3	0.900	
S4	0.967	
S7	-0.970	
S8	0.932	
S9		0.986
S11	0.979	
S12	-0.977	
S13	0.933	
S14		0.996
S15	0.947	
S17	0.915	
S20	-0.945	
S21	-0.943	
Proportion Var	0.767	0.161
Cumulative Var	0.767	0.928

Từ ma trận hệ số tải sau phép xoay Varimax (Bảng 24), ta có thể rút ra các kết luận


thống kê về cấu trúc tiềm ẩn (Latent Structure) của dữ liệu:

- **Nhân tố ML2 (Đại diện cho Quá trình Mài mòn - tương đương PC_1):**
Đóng góp phần lớn vào sự biến thiên (76.7%) và tập trung sự ảnh hưởng của 12/14 cảm biến cốt lõi. Sự phân cực dấu âm/dương rõ nét (ví dụ: S7, S12, S20, S21 mang dấu âm, phần còn lại mang dấu dương) đã minh họa tính thuận/nghịch của các thông số nhiệt động lực học khi động cơ dần suy thoái.
- **Nhân tố ML1 (Đại diện cho Biến thiên Vận hành - tương đương PC_2):**
Giải thích 16.1% phương sai và được định hình chủ yếu bởi S9 và S14. Sự tách bạch tương đối rõ ràng này cho thấy S9 và S14 mang một đặc tính cơ học thứ cấp khác biệt, không nên gộp chung vào Chỉ số Sức khỏe.

Bên cạnh đó, chỉ số **Communality** (Bảng 25 và Hình 30) đo lường mức độ biến thiên của từng cảm biến được giải thích bởi các nhân tố chung. Đa số các cảm biến đều đạt ngưỡng Communality rất cao (trên 0.8), vượt xa ngưỡng chấp nhận 0.5. Điều này chứng minh PC_1 thực sự là một cấu trúc tiềm ẩn (Latent Construct) mang ý nghĩa vật lý rõ nét, đại diện cho tình trạng hao mòn chung của hệ thống.

Bảng 25: Chỉ số Communality của các cảm biến

Biến	S2	S3	S4	S7	S8	S9	S11	S12	S13	S14	S15	S17	S20	S21
Chỉ số	0.878	0.843	0.945	0.941	0.948	0.990	0.962	0.955	0.949	0.992	0.911	0.872	0.905	0.902




Hình 30: Biểu đồ Communality: Tất cả các cảm biến đều có mức độ giải thích vượt xa ngưỡng 0.5.

Việc áp dụng song song PCA và EFA đã hoàn thành xuất sắc mục tiêu trích xuất đặc

trưng. Trong khi PCA tổng hợp biến động toàn cục thành một Chỉ số Sức khỏe duy nhất (PC_1), EFA củng cố kết quả này bằng cách bóc tách rõ ràng nguồn gốc vật lý của các cụm cảm biến. Tất cả các biến đều thể hiện mức độ hội tụ rất cao, khẳng định không có cảm biến cốt lõi nào bị "lạc lõng" hay mang thông tin nhiễu loạn ngoài hệ thống.


4.3.5 Phân tích Quỹ đạo Sức khỏe và Cảnh báo sớm

Quỹ đạo PC_1 của các động cơ ngẫu nhiên (Hình 31) cho thấy dù xuất phát điểm khác nhau do điều kiện vận hành, tất cả đều hội tụ về một quy luật hàm mũ chung ở giai đoạn cuối vòng đời.




Hình 31: Quỹ đạo Chỉ số Sức khỏe (PC_1 Kalman) của 5 động cơ ngẫu nhiên.

Dựa trên không gian 3 chiều (PC_1, PC_2, PC_3), **Khoảng cách Mahalanobis** được tính toán so với tâm phân phối của trạng thái khỏe mạnh (30 chu kỳ đầu). Hình 32 minh họa đường cong cảnh báo sớm, hệ thống thể hiện khả năng phát hiện điểm bất thường khi khoảng cách bắt đầu vượt qua ngưỡng nguy hiểm.



Hình 32: Đường cong Cảnh báo sớm dựa trên Khoảng cách Mahalanobis đa chiều.

Bên cạnh khoảng cách Mahalanobis, **Biểu đồ kiểm soát Hotelling T^2** (Multivariate Control Chart) được thiết lập nhằm xác định ngưỡng cảnh báo trên (UCL) một cách khách quan và chặt chẽ hơn về mặt thống kê [7]. Cụ thể, UCL được tính toán dựa trên phân phối F với mức ý nghĩa $\alpha = 0.05$ (đạt giá trị 7.83). Bất kỳ quan sát nào vượt ngưỡng này đều kích hoạt tín hiệu cảnh báo suy thoái (Hình 33).




Hình 33: Biểu đồ Kiểm soát Hotelling T^2 : Cảnh báo sớm với ngưỡng UCL dựa trên phân phối F.

Việc kết hợp Chỉ số Sức khỏe (PC_1) với các thước đo khoảng cách đa chiều (Mahalanobis và Hotelling T^2) đã thiết lập nên một cơ chế giám sát sức khỏe động cơ toàn diện. Cơ chế này không chỉ mô tả chính xác sự tiến triển của suy thoái mà còn cung cấp các ngưỡng cảnh báo sớm khách quan về mặt thống kê, tạo tiền đề vững chắc cho chiến lược bảo trì tiên đoán (Predictive Maintenance).


4.3.6 Bộ lọc Kalman, Phân cụm GMM và Phân tích Biệt thức

Trong bài toán bảo trì thực tế, ta thường không có sẵn nhãn (label) chỉ định chính xác khi nào động cơ bắt đầu hỏng. Do đó, **Mô hình Hỗn hợp Gauss (GMM)** được sử dụng như một phương pháp Học Không giám sát (Unsupervised Learning) nhằm tự động khám phá các "pha" (trạng thái) suy thoái ẩn bên trong hệ thống dựa trên sự phân bố mật độ xác suất của dữ liệu. Đồng thời, GMM cũng đóng vai trò làm thước đo khách quan để so sánh chất lượng của các bộ lọc nhiễu. Cụ thể, khi áp dụng GMM trên không gian PC_1 , điểm số Bayesian Information Criterion (BIC) của dữ liệu lọc bằng Kalman đạt mức cao hơn đáng kể (-105010.27) so với dữ liệu lọc bằng Moving Average (-105609.86) (theo quy ước của thư viện `mclust`, BIC càng lớn càng tốt). Điều này cho thấy Kalman Filter đã bảo toàn cấu trúc phân phối ngầm của hệ thống cơ học ưu việt hơn, giúp dữ liệu hội tụ thành các cụm trạng thái sắc nét hơn.

Dựa trên tiêu chuẩn BIC tổng quát (Hình 34), thuật toán đạt cực đại tại 5 cụm (V,5: -104795.3). Tuy nhiên, dựa trên nguyên lý Occam's Razor và khả năng diễn giải vật lý (Domain Knowledge), cấu trúc 3 cụm ($G = 3$) được lựa chọn làm giải pháp tối ưu. Cấu hình này tương ứng phù hợp với 3 pha suy thoái thực tế của động cơ (Hình 35): Vùng An toàn (Cụm 2 - màu xanh dương), Vùng Bắt đầu suy thoái (Cụm 3 - màu xanh lá) và Vùng Nguy hiểm (Cụm 1 - màu đỏ).




Hình 34: Đường cong BIC: Đỉnh cao nhất tại $G = 5$, nhưng $G = 3$ được chọn vì tính thực tiễn cơ học.



Hình 35: Phân cụm GMM ($G = 3$) tự động nhận diện 3 pha suy thoái trên PC_1 (Động cơ 1).

Việc ánh xạ 3 cụm này lên không gian 2 chiều $PC_1 - PC_2$ kèm theo Ellipse tin cậy 95% (Hình 36) bộc lộ rõ sự phân tách ranh giới giữa các pha thoái hóa.



Hình 36: Không gian PC1-PC2 với Ellipse tin cậy 95%: 3 vùng trạng thái tách biệt rõ ràng.

Để xác nhận tính vững chắc của các cụm phân lớp GMM, **Phân tích Biệt thức Tuyến tính (LDA)** được sử dụng như một phép kiểm định ngược (Post-hoc Validation) có giám sát. Ở đây, LDA đóng vai trò đánh giá xem các cụm GMM sinh ra có thực sự phân tách tuyến tính rõ rệt trong không gian thành phần chính hay không, và thành phần nào đóng góp nhiều nhất vào việc phân loại.

Bảng 26: Kết quả Phân tích Biệt thức Tuyến tính (LDA) trên 3 cụm GMM

Xác suất tiên nghiệm (Prior probabilities of groups):			
	Cụm 1 (Khỏe)	Cụm 2 (Suy thoái)	Cụm 3 (Nguy hiểm)
	0.1699	0.6445	0.1855
Trung bình nhóm (Group means):			
	PC1_KF	PC2	PC3
Cụm 1	-5.6096	0.3897	0.0097
Cụm 2	0.2399	-0.2104	-0.0044
Cụm 3	4.3044	0.3741	0.0063
Hệ số hàm phân biệt tuyến tính (Coefficients of linear discriminants):			
	LD1	LD2	
PC1_KF	0.6611	0.0088	
PC2	-0.0422	0.6874	
PC3	-0.0369	0.2674	
Tỷ lệ phương sai giải thích (Proportion of trace):			
	LD1: 99.03%	LD2: 0.97%	

Kết quả LDA (Bảng 26) cho thấy hàm biệt thức thứ nhất (LD_1) giải thích tới 99.03% sự khác biệt giữa 3 trạng thái suy thoái. Đặc biệt, hệ số của PC_1_KF trong LD_1 đạt 0.661, rất cao so với các biến khác, chỉ ra rằng PC_1 chính là nhân tố chủ đạo chi phối ranh giới hồng học. Hơn nữa, trung bình nhóm (Group means) dọc theo trục PC_1_KF có sự chuyển dịch định lượng rõ nét từ -5.61 (Cụm 1 - Khỏe mạnh), sang 0.24 (Cụm 2 - Suy thoái), và 4.30 (Cụm 3 - Nguy hiểm). Sự phân hóa tuyến tính rõ rệt này giúp mô hình LDA đạt tỷ lệ phân loại lại (resubstitution accuracy) khớp với GMM lên tới hơn 95%, gợi ý rằng việc phân cụm của GMM bám sát quỹ đạo biến thiên cơ học chứ không phải gom cụm ngẫu nhiên.

4.3.7 Đánh giá Hiệu năng Hồi quy (RMSE) và Phần dư

Đóng vai trò như khâu đánh giá cuối cùng để kiểm chứng khả năng trích xuất thông tin của toàn bộ quy trình, PC_1 (Chỉ số Sức khỏe) được đưa vào mô hình Hồi quy Đa thức bậc 3 (Polynomial Regression) nhằm dự báo RUL. Bảng 27 trình bày kết quả đánh giá thông qua sai số bình phương trung bình (RMSE) trên tập Test độc lập.


Bảng 27: Bảng tổng hợp so sánh hiệu năng Hồi quy và Kiểm định Thống kê

Phương pháp	Số biến	RMSE	Đặc điểm
MLR (14 biến gốc)	14	21.90	Đa cộng tuyến cao, Overfit
PCR + Moving Average	1 (PC_1)	28.01	Trễ pha (Lag)
PCR + Kalman Filter	1 (PC_1)	23.35	Ổn định, bám sát vật lý

Nhìn vào kết quả, thoát tiên Mô hình Hồi quy Đa biến (MLR) sử dụng toàn bộ 14 cảm biến gốc cho ra mức RMSE thấp nhất (21.90). Tuy nhiên, dưới lăng kính Thống kê học, đây lại là biểu hiện kinh điển của hiện tượng quá khớp (Overfitting) do Đa cộng tuyến nghiêm trọng (Variance Inflation) đã được chỉ ra qua kiểm định KMO và Bartlett trước đó. Mô hình MLR "học vẹt" cả nhiễu cục bộ của dữ liệu nên sẽ thiếu tính tổng quát hóa trên dữ liệu thực tế mới.

Ngược lại, phương pháp Hồi quy Thành phần Chính (Principal Component Regression - PCR) với 1 biến duy nhất (PC_1) thể hiện lợi thế của nguyên lý đánh đổi Bias-Variance Tradeoff. Trong đó, mô hình **PCR kết hợp Kalman Filter** đạt mức RMSE 23.35, tốt hơn đáng kể so với mô hình PCR dùng Moving Average (28.01). Sự chênh lệch này xuất phát từ hiện tượng "trễ pha" (lag) cố hữu của Moving Average, khiến dự báo bị lệch nhịp ở giai đoạn cuối khi gia tốc động cơ suy thoái tăng vọt (theo hàm mũ). Kalman Filter, nhờ cơ chế cập nhật không gian trạng thái động (State-Space), đã khử nhiễu sắc bén mà không làm mất đi thông tin biến thiên gia tốc. Việc hy sinh một phần nhỏ độ chính xác (so với MLR) để đổi lấy một mô hình chỉ dùng 1 chiều không gian nhưng rất ổn định, vững chãi là một kết quả tốt về mặt kỹ thuật nén thông tin.

Bên cạnh đó, việc kiểm định giả định hồi quy thông qua phân tích Phần dư (Residuals Analysis) của mô hình PCR Kalman (Hình 37) càng củng cố thêm tính hợp lệ của phương pháp. Biểu đồ phân tán phần dư cho thấy các điểm sai số dao động ngẫu nhiên quanh trục trung bình 0 (zero-mean) và không tạo thành cấu trúc dạng phễu. Điều này cho thấy phương sai sai số là không đổi (Homoscedasticity). Hơn nữa, việc không xuất hiện các mẫu hình hệ thống (như hình chữ U) gợi ý rằng Hồi quy Đa thức bậc 3 đã bao quát (fit) tốt độ cong phi tuyến của quá trình suy thoái cơ học ở các chu kỳ cuối, khắc phục đáng kể hiện tượng thiếu khớp (Underfitting) - hệ quả tất yếu nếu chỉ dùng hồi quy tuyến tính bậc 1 cho dữ liệu có quỹ đạo phi tuyến.



Hình 37: Phân tích Phần dư (Residuals): Phần dư phân tán ngẫu nhiên, mô hình không bị thiên lệch và đáp ứng giả định phương sai đồng nhất (Homoscedasticity).

4.3.8 Tổng kết Phần 3 (Conclusion)

Nghiên cứu đã thiết lập thành công một quy trình thống kê khép kín để giải quyết trọn vẹn bài toán trích xuất tín hiệu và dự báo vòng đời động cơ máy bay. Việc kết hợp Bộ lọc Kalman (để khử nhiễu động học) cùng phương pháp Phân tích Thành phần Chính PCA và EFA (để khắc phục đa cộng tuyến) đã thu gọn 14 dải tín hiệu cảm biến hỗn loạn thành một Chỉ số Sức khỏe cốt lõi (PC_1) duy nhất. Quỹ đạo suy thoái PC_1 này không chỉ mang đậm ý nghĩa vật lý mà còn là nền tảng vững chắc để xây dựng cơ chế cảnh báo sớm thông qua khoảng cách Mahalanobis và biểu đồ kiểm soát Hotelling T^2 . Hơn thế nữa, tín hiệu PC_1 đã cho phép thuật toán Mô hình Hỗn hợp Gauss (GMM) tự động phân tách và nhận diện ba pha suy thoái ẩn của hệ thống, đồng thời hỗ trợ mô hình hồi quy đa thức dự báo RUL với sai số tối ưu. Kết quả trên đã khẳng định tính vượt trội của việc kết hợp lý thuyết lọc tín hiệu đa chiều trong bài toán bảo trì tiên đoán (Predictive Maintenance).

5 Thảo luận và Hướng phát triển (Discussion & Future Directions)

5.1 Tổng hợp và Ý nghĩa Thực tiễn (Cross-Domain Practical Implications)

Dù ba bộ dữ liệu mang đặc thù hoàn toàn khác biệt (Y tế, Giáo dục, Cơ học), việc ứng dụng Thống kê Nhiều chiều đã chứng minh sức mạnh bao quát và tính nhất quán trong khả năng giải mã các hệ thống phức tạp:

- **Bóc tách mạng lưới nhân quả:** Trong bài toán Y tế (Phần 1), PCA và MANOVA đã lượng hóa chính xác mức độ tổn thương kép lên hệ thần kinh và tim mạch của hội chứng Ngưng thở khi ngủ. Trong khi đó ở bài toán Giáo dục (Phần 2), Multivariate LR và K-Means giúp kiểm định đồng thời nhiều kết quả học thuật, tránh lạm phát sai lầm Loại I và định lượng sức ảnh hưởng thống trị của biến thời gian tự học.
- **Nhận diện Đặc trưng Cốt lõi (Feature Extraction):** Ở bài toán Cơ học C-MAPSS (Phần 3), trước hàng loạt cảm biến mang tính đa cộng tuyến và bị vùi lấp bởi nhiễu, thuật toán PCA kết hợp Bộ lọc Kalman đã trích xuất thành công một *Chỉ số Sức khỏe* (PC_1) duy nhất. Chỉ số này mang đầy đủ đặc tính vật lý của sự thoái hóa, tạo nền tảng vững chắc để thiết lập giới hạn cảnh báo sớm Hotelling T^2 cho hệ thống Bảo trì Tiên đoán (Predictive Maintenance).

5.2 Giới hạn chung của các Phương pháp (Methodological Limitations)

Tuy đạt được những kết quả đáng tin cậy, các mô hình thống kê trong nghiên cứu này vẫn tồn tại một số giới hạn toán học nhất định:

- **Dữ liệu cắt ngang và Giới hạn Nhân quả (Cross-sectional & Causality):** Cả hai phân tích trong Phần 1 (Y tế) và Phần 2 (Giáo dục) đều dựa trên dữ liệu cắt ngang. Vì vậy, các phương pháp như MANOVA hay Multivariate LR chỉ có thể xác lập độ tương quan (correlation) và sự đồng biến, chứ chưa đủ cơ sở để khẳng định mối quan hệ nhân quả (causality) trực tiếp.
- **Hiện tượng Biến ẩn (Omitted Variable Bias):** Sự tồn tại của tương quan phần dư khá lớn trong mô hình hồi quy ở Phần 2 cho thấy còn nhiều biến ẩn (Latent Variables) chi phối hệ thống (như môi trường gia đình, phương pháp học, yếu tố di truyền y khoa) chưa được thu thập, dẫn đến việc mô hình chưa giải thích được trọn vẹn phương sai tổng thể.
- **Vi phạm giả định Phân phối Chuẩn Đa chiều:** Ở Phần 3, kiểm định Mardia chỉ ra rằng dữ liệu C-MAPSS bị lệch chuẩn nặng ở vùng đuôi (heavy-tailed). Điều

này làm suy giảm một phần tính hiệu quả của các phép chiếu không gian tuyến tính thuần túy như PCA ở các chu kỳ suy thoái cực đoan (cuối vòng đời động cơ).

5.3 Định hướng phát triển theo Thống kê Nhiều chiều (Advanced Statistical Directions)

Để giải quyết triệt để các giới hạn trên, nghiên cứu đề xuất các hướng đi chuyên sâu tập trung vào Toán Thống kê và Mô hình hóa Cao cấp thay vì phụ thuộc hoàn toàn vào các thuật toán hộp đen (black-box ML):

- **Mô hình Phương trình Cấu trúc (Structural Equation Modeling - SEM):** Thay thế cho kiến trúc MANOVA và LR rời rạc, SEM cho phép thiết lập hệ thống phương trình định lượng trực tiếp các biến ẩn (Latent Variables), mô phỏng mạng lưới tác động gián tiếp (Mediation/Moderation Effects) và cung cấp bằng chứng suy diễn nhân quả (Causal Inference) mạnh mẽ hơn cho khoa học hành vi và y tế.
- **Giảm chiều Phi tuyến & Phân tích Nhân tố Động (Non-linear PCA & Dynamic Factor Analysis):** Để khắc phục giới hạn của PCA truyền thống khi dữ liệu vi phạm phân phối chuẩn (như trong C-MAPSS), việc mở rộng sang Kernel PCA hoặc DFA (Dynamic Factor Analysis) sẽ giúp mô hình hóa trọn vẹn quỹ đạo phi tuyến hàm mũ tại pha hồng học cực đoan, bao quát tốt hơn vùng đuôi phân phối.
- **Mô hình Tự hồi quy Vector & Không gian Trạng thái (VAR & State-Space Models):** Thay vì xử lý dữ liệu C-MAPSS như một cấu trúc tĩnh tĩnh, việc tích hợp Mô hình Tự hồi quy Vector (Vector Autoregression - VAR) kết hợp sâu hơn với Bộ lọc Kalman trong một Không gian Trạng thái (State-Space) sẽ khai thác tối đa tương quan động học (temporal dynamics) của chuỗi thời gian đa biến, mang lại sai số dự báo (RMSE) thấp và vững chãi hơn.
- **Mô hình Hồi quy Phức hợp (Tobit / Ordinal Logistic):** Sử dụng phương pháp Tobit Regression để xử lý triệt để hiện tượng bị chặn trên (right-censored) do hiệu ứng trần (ceiling effect) của thang điểm thi sinh viên, đảm bảo các ước lượng không bị thiên lệch ở vùng điểm tối đa.

6 Kết luận (Conclusion)

Đồ án đã tiến hành tiếp cận và phân tích ba bộ dữ liệu mang đặc tính khác biệt thông qua các phương pháp Thống kê Nhiều chiều. Quá trình thực hiện đã cung cấp các góc nhìn định lượng và hỗ trợ diễn giải cấu trúc tiềm ẩn của dữ liệu trong từng bối cảnh cụ thể.

Đối với dữ liệu y tế (Sleep Health), việc kết hợp PCA và MANOVA đã hỗ trợ lượng hóa sự khác biệt về mặt cấu trúc triệu chứng giữa các nhóm rối loạn giấc ngủ, đồng thời mô tả mức độ biến thiên đa chiều của hệ tim mạch và trạng thái thần kinh.

Đối với dữ liệu xã hội học (Student Habits), thông qua MANOVA, Multivariate LR và K-Means, nghiên cứu đã đánh giá mức độ đồng biến giữa các thói quen sinh hoạt và thành quả học tập. Kết quả quan sát ghi nhận thời gian tự học có tỷ lệ giải thích (variance explained) cao nhất trong các mô hình được khảo sát. Quá trình phân tích cũng nhận diện được những hạn chế của mô hình tuyến tính trên bộ dữ liệu này, bao gồm hiệu ứng trần (ceiling effect) và ảnh hưởng của các biến chưa được thu thập (omitted variables).

Đối với dữ liệu chuỗi thời gian cơ học (C-MAPSS), quy trình phân tích bao gồm Bộ lọc Kalman, PCA, EFA và GMM đã góp phần xử lý nhiễu động học và trích xuất thành phần chính đại diện cho xu hướng thoái hóa cơ học. Việc kết hợp các phép đo khoảng cách đa chiều (Mahalanobis, Hotelling T^2) đã cung cấp các cơ sở thống kê để thiết lập ngưỡng quan sát, từ đó hỗ trợ phương án tiếp cận cho bài toán giám sát tình trạng và dự báo thời gian sống hữu ích còn lại (RUL) của động cơ.

Tài liệu tham khảo (References)

Tài liệu

- [1] Saxena, A., Goebel, K., Simon, D., & Eklund, N. (2008). *Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation*. In 2008 International Conference on Prognostics and Health Management (pp. 1-9). IEEE.
- [2] Macian, V., et al. (2019). *A comparative study of dimensionality reduction techniques for remaining useful life prediction*. Reliability Engineering & System Safety.
- [3] Zinchuk, A. V., et al. (2018). *Polysomnographic phenotypes and their cardiovascular implications in obstructive sleep apnoea*. Thorax, 73(5), 472-480.
- [4] Credé, M., & Kuncel, N. R. (2008). *Study habits, skills, and attitudes: The third pillar supporting collegiate academic performance*. Perspectives on Psychological Science, 3(6), 425-453.
- [5] Romero, C., & Ventura, S. (2010). *Educational data mining: a review of the state of the art*. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 40(6), 601-618.
- [6] Tabachnick, B. G., & Fidell, L. S. (2013). *Using Multivariate Statistics* (6th ed.). Pearson.
- [7] Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6th ed.). Pearson.
- [8] Nguyễn Thị Mộng Ngọc, Đinh Ngọc Thanh, Đặng Đức Trọng. *Thống kê nhiều chiều*.
- [9] Anderson, T. W. (2003). *An Introduction to Multivariate Statistical Analysis* (3rd ed.). Wiley.
- [10] Box, G. E., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: forecasting and control*. John Wiley & Sons.
- [11] Welch, G., & Bishop, G. (1995). *An introduction to the Kalman filter*. University of North Carolina at Chapel Hill.
- [12] McLachlan, G., & Peel, D. (2000). *Finite Mixture Models*. John Wiley & Sons.
- [13] Schwarz, G. (1978). *Estimating the dimension of a model*. The annals of statistics, 6(2), 461-464.
- [14] NASA Ames Prognostics Data Repository. *Turbofan Engine Degradation Simulation Data Set*.

- [15] Kaggle. *Sleep Health and Lifestyle Dataset*.
- [16] Kaggle. *Student Habits vs Academic Performance Dataset*.

Bảng Phân Công Công Việc (Task Assignment)

STT	Họ và tên	Công việc phụ trách	Hoàn thành
1	Nguyễn Minh Quang	Phần 3 (CMAPSS Data), hỗ trợ và chỉnh sửa các phần, viết báo cáo	100%
2	Nguyễn Hoàng Phúc	Phần 2 (Student Data), hỗ trợ viết và chỉnh sửa báo cáo	100%
3	Hà Tuấn Kiệt	Phần 1 (Sleep Data), hỗ trợ viết và chỉnh sửa báo cáo	100%

Phụ lục: Mã nguồn và Dữ liệu thực nghiệm

Nhằm đảm bảo tính minh bạch và khả năng tái lập (reproducibility) của nghiên cứu, toàn bộ mã nguồn ngôn ngữ R cùng các bộ dữ liệu gốc đã được nhóm tác giả đóng gói thành các tệp tin nén theo đúng quy chuẩn nộp đồ án. Cụ thể, các tệp đính kèm bao gồm:

- **Tệp tin Mã nguồn:** Chứa file R Markdown (`.Rmd`) và báo cáo thực thi (`.html`), thể hiện chi tiết toàn bộ quá trình tiền xử lý, các lệnh gọi hàm Thống kê và output console tương ứng.
- **Tệp tin Dữ liệu (data-nhom):** Chứa nguyên bản 3 bộ dữ liệu (Sleep Health, Student Habits, NASA C-MAPSS) đã được sử dụng xuyên suốt trong bài.

Kính mời cô tham khảo các tệp tin nén này để kiểm chứng chi tiết các bước cài đặt thuật toán và kết quả thực nghiệm.

Ghi chú: Trong trường hợp các tệp đính kèm gặp sự cố kỹ thuật hoặc lỗi giải nén, toàn bộ mã nguồn và tập dữ liệu đã được lưu trữ dự phòng trên nền tảng GitHub. Kính mời cô truy cập trực tiếp vào kho lưu trữ của nhóm tại địa chỉ:

<https://github.com/minhquang0407/tknc-projects>